Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Audit Generalisasi Deteksi Phishing URL: Saturasi Benchmark pada PhiUSIIL, Evaluasi Temporal, dan Transfer Lintas-Korpus ke PhreshPhish

Auditing Phishing URL Detection Generalization: Benchmark Saturation on PhiUSIIL, Temporal Evaluation, and Cross-Corpus Transfer to PhreshPhish

[Nama Penulis 1][1], [Nama Penulis 2][1], [Nama Penulis 3][2]*
[1][Program Studi], [Fakultas], [Nama Institusi], [Kota], Indonesia
[2][Program Studi], [Fakultas], [Nama Institusi], [Kota], Indonesia
Email: [email penulis 1], [email penulis 2], *[email penulis korespondensi]
Email Penulis Korespondensi: [email penulis korespondensi] (sesuai tanda bintang pada susunan penulis)
[Tanggal penerimaan, revisi, penerimaan terbit, dan tanggal terbit diisi oleh editor]

Abstrak

Kami menguji bagaimana hasil deteksi phishing URL berubah ketika unit pembagian, waktu, dan korpus berbeda menggunakan dua dataset phishing URL. Desain mencakup audit keterpulihan label, pembagian acak dan *site-disjoint*, ablasi kelompok fitur, evaluasi temporal dalam-korpus pada PhreshPhish, transfer A2 *zero-shot* tanpa adaptasi, pemilihan ambang hanya pada validasi, dan analisis galat deskriptif. Pada PhiUSIIL, A0/LightGBM mencapai F1 0,999623 pada pembagian *site-disjoint*; dua fitur yang dipertahankan masing-masing memiliki AUC tunggal sekitar 0,988 atau lebih, konsisten dengan saturasi benchmark deskriptif tetapi tidak mengidentifikasi peny*ebabnya*. Pada PhreshPhish, A2/LightGBM mencapai rerata F1 temporal 0,800461. A2/LightGBM yang dilatih hanya pada PhiUSIIL mencapai F1 0,599064, FPR benign 0,986478, ROC-AUC 0,382566, dan MCC −0,146445 pada 168.035 URL PhreshPhish, dibandingkan F1 sumber 0,995985; pada arah sebaliknya, model yang dilatih pada blok fit PhreshPhish dan diuji pada 235.370 URL PhiUSIIL mencapai F1 0,549564, FPR benign 0,897783, ROC-AUC 0,642939, dan MCC −0,092320. Temuan ini menggambarkan portabilitas pada pasangan yang diuji dan tidak menentukan penyebab temporal. Partisi uji temporal telah diperiksa dalam pekerjaan eksploratif sebelumnya sehingga bukan holdout buta atau prospektif. Dalam refit temporal terpisah, ambang 0,884705 yang dipilih untuk memenuhi FPR validasi ≤1% menghasilkan FPR uji 1,1352% dan recall 0,5440, dibandingkan 7,6497% dan 0,7380 pada ambang 0,5. Analisis galat menemukan 37,1% dari seluruh *FN* pada kategori host platform dan FPR 21,8% pada URL benign ≤30 karakter; kategori tumpang tindih ini bersifat deskriptif dan ketidakpastian klaster platform tidak terverifikasi. Kontribusi artikel adalah perbandingan yang dapat diaudit atas saturasi benchmark, evaluasi temporal, transfer lintas-korpus dua arah, trade-off ambang, dan pola galat deskriptif; bukan model baru atau *klaim state-of-the-art*.

Kata kunci: deteksi phishing URL, generalisasi lintas-korpus, evaluasi temporal, saturasi benchmark, pemilihan ambang, analisis galat, PhiUSIIL, PhreshPhish

Abstract

We examine how phishing URL detection results vary across split unit, time, and corpus using two phishing-URL datasets. The study combines a label-recoverability audit, random and site-disjoint splits, grouped feature ablation, within-corpus temporal evaluation on PhreshPhish, two-direction frozen A2 zero-shot transfer, validation-only threshold selection, and descriptive error analysis. On PhiUSIIL, A0/LightGBM achieved site-disjoint F1 0.999623; two retained features each had single-feature AUC of about 0.988 or more, consistent with descriptive benchmark saturation but not identifying its cause. PhreshPhish temporal A2/LightGBM achieved mean F1 0.800461. A2/LightGBM trained only on PhiUSIIL achieved F1 0.599064, benign FPR 0.986478, ROC-AUC 0.382566, and MCC −0.146445 on 168,035 PhreshPhish URLs, compared with source-domain F1 0.995985; in the reverse direction, training on the PhreshPhish fit block and testing on 235,370 PhiUSIIL URLs achieved F1 0.549564, benign FPR 0.897783, ROC-AUC 0.642939, and MCC −0.092320. These results describe portability on the tested pair and do not identify a temporal cause. The temporal test partition had previously been inspected in exploratory work and was not a blind or prospective holdout. In a separate temporal refit, threshold 0.884705 selected to meet validation FPR ≤1% yielded test FPR 1.1352% and recall 0.5440, compared with 7.6497% and 0.7380 at threshold 0.5. Error analysis found 37.1% of all false negatives in the hosting-platform category and 21.8% FPR among benign URLs ≤30 characters; these overlapping categories are descriptive, and platform-cluster uncertainty was not verified. The contribution is an auditable comparison of benchmark saturation, temporal evaluation, two-direction cross-corpus transfer, threshold trade-offs, and descriptive error patterns, not a new model or state-of-the-art claim.

Keywords: phishing URL detection, cross-corpus generalization, temporal evaluation, benchmark saturation, threshold selection, error analysis, PhiUSIIL, PhreshPhish

1. PENDAHULUAN

Phishing URL merupakan masalah klasifikasi yang sangat dipengaruhi oleh cara dataset dikumpulkan dan dibagi. Literatur metodologis telah memperingatkan bahwa rancangan dataset, ketidakmandirian sampel, dan kebocoran antarlatih-uji dapat menghasilkan estimasi yang terlalu optimistis [3], [5], [6]. PhishBench juga menunjukkan pentingnya kondisi pembandingan yang seragam, rasio kelas, dan evaluasi pada dataset yang beragam [4]. Tinjauan sistematis terbaru atas taksonomi deteksi situs phishing menegaskan bahwa kategori berbasis URL, konten, dan visual memiliki batas masing-masing, dan bahwa celah penelitian utama terletak pada konsistensi evaluasi [28]. Dalam konteks phishing, validitas temporal dan pilihan dataset turut membatasi arti angka evaluasi yang dilaporkan [7], [8]. Pengalaman pada klasifikasi

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

malware menunjukkan bahwa skor F1 yang dilaporkan mendekati 0,99 dapat berasal dari bias spasial dan temporal pada rancangan eksperimen, bukan dari kemampuan model yang sebenarnya [13].

Pembagian acak pada tingkat baris tidak menjamin bahwa entitas yang mendasari sampel telah terpisah. URL uji dapat berbagi registrable domain atau pola kampanye dengan URL latih, sehingga angka uji dapat mencampur generalisasi ke entitas baru dengan pengenalan entitas yang telah terlihat. Sebaliknya, pemisahan berdasarkan registrable domain juga bukan solusi sempurna: platform multi-tenant dapat menggabungkan banyak penyewa independen ke dalam satu kunci domain. Karena itu, protokol dan granularitas kelompok harus diperlakukan sebagai bagian dari klaim penelitian, bukan sekadar detail implementasi [3], [5]. Pada sisi waktu, deteksi drift konsep menunjukkan bahwa model dapat menua selama penerapan sebelum penurunan kinerja terukur [14], dan evaluasi ulang terhadap pendekatan itu menegaskan bahwa kesimpulan tentang drift bergantung pada protokol pemisahan waktu [15]. Tinjauan metodologis terbaru menempatkan drift, evolusi label tertunda, dan pergeseran distribusi sebagai sumber masalah utama dalam evaluasi keamanan berbasis pembelajaran mesin, bukan sebagai detail implementasi [29].

Studi lintas-dataset menunjukkan bahwa keandalan fitur phishing tidak otomatis berpindah ke dataset lain [9]. PhreshPhish secara khusus dibangun untuk mengurangi duplikasi dan kebocoran serta menyediakan informasi temporal, sekaligus menyoroti base rate yang lebih realistis [2]. Sementara itu, studi pada venue BITS telah melaporkan klasifikasi URL dengan SVM dan XGBoost [11], [12], tetapi artikel ini mengambil posisi berbeda: bukan mengusulkan pengklasifikasi baru, melainkan menguji seberapa banyak kesimpulan berubah setelah struktur domain, kelompok fitur, dan waktu diperhatikan.

1.1 Posisi Penelitian terhadap Related Work

Tabel 1 membandingkan desain evaluasi tiap kelompok literatur dan batas pemakaiannya dalam penelitian ini. Kolom batas tidak digunakan untuk menyatakan bahwa studi terdahulu "tidak melakukan" suatu eksperimen tanpa bukti; kolom itu hanya menjelaskan sejauh mana sumber tersebut dipakai untuk menopang klaim artikel ini. Isian "tidak dilaporkan pada abstrak" berarti informasi tersebut tidak tersedia pada sumber yang diperiksa, bukan berarti studi tidak melakukannya.

Tabel 1. Perbandingan desain evaluasi dan batas pemakaian literatur utama.

Sumber	Korpus, domain, dan unit pembagian	Desain waktu, adaptasi, dan ambang	Batas pemakaian
Marchal dan Asokan [3]	Deteksi halaman phishing; unit pembagian tidak dilaporkan pada abstrak	Mengusulkan protokol evaluasi untuk kondisi nyata, termasuk studi longitudinal pada interval waktu tetap dengan dan tanpa pelatihan ulang; tidak menjalankan transfer lintas korpus	Tidak memindahkan angka atau efek protokol ke PhiUSIIL
PhishBench (El Aassal et al.) [4]	Banyak dataset deteksi phishing; kondisi pembandingan diseragamkan	Menguji ulang metode pada dataset baru dan beragam, termasuk pengaruh rasio kelas; menyatakan pelatihan ulang saja tidak cukup menghadapi serangan baru; protokol ambang tidak dilaporkan pada abstrak	Penelitian ini tidak menggunakan pipeline PhishBench
Arp et al. [5]; Kapoor dan Narayanan [6]	Lintas domain keamanan dan sains; unit entitas dan kebocoran data	Kerangka umum, bukan estimasi besaran efek	Prinsip umum; bukan estimasi efek pada phishing URL
Mia et al. [9]	Fitur phishing lintas dataset; korpus berbeda-beda	Uji transfer model lintas dataset dua arah dengan fitur bersama; protokol ambangnya tidak dinyatakan pada sumber yang diperiksa	Protokol, fitur, dan pasangan korpus berbeda; bukan replikasi langsung
Nabila et al. [11]; Yoga et al. [12]	Klasifikasi phishing URL dan website pada venue BITS; evaluasi dalam-korpus	Pembagian dalam-korpus pada satu dataset per studi (80/20 berstrata pada [11]; 70/30 pada [12]); tidak ada pemisahan berbasis waktu dan tidak ada transfer lintas korpus	Tidak ada klaim peningkatan model atas kedua studi
TESSERACT (Pendlebury et al.) [13]	Malware Android; 129 ribu aplikasi lintas tiga tahun; batas ruang dan waktu	Batas waktu eksplisit; metrik ketahanan yang diharapkan	Domain malware; tidak memindahkan besaran efek ke phishing URL
Transcend (Jordaney et al.) [14]; Barbero et al. [15]	Malware Android dan Windows [14]; Android saja pada [15]	Deteksi drift saat penerapan; penolakan prediksi berisiko	Tidak memberi protokol ambang lintas korpus untuk phishing URL
Safi dan Singh [16]; Karim et al. [17]; Gupta et al. [18]; Sanchez-Paniagua et al. [19]; Aljofey et al. [20]	Phishing website dan URL; korpus berbeda-beda; komposisi uji mengubah FPR [19]	Umumnya evaluasi dalam-korpus; representasi URL-saja atau hibrida	Perbandingan angka tidak dilakukan karena korpus dan protokol berbeda
Ahamed et al. [24]	PhiUSIIL 235.370 URL tervalidasi; validasi eksternal memakai 49.121 URL PhishTank, dengan kelas benign diambil dari split uji PhiUSIIL yang dipegang	Robustness adversarial, generalisasi leave-one-family-out, stabilitas penjelasan, dan validasi eksternal yang hanya eksternal pada sisi phishing (Subbagian 4.6 pada [24]), karena kelas benign diambil dari PhiUSIIL	Sumbu pembandingnya robustness; evaluasi temporal berbasis waktu dan ambang berbasis validasi tidak dilaporkan di sana
Ahmed et al. [25]	Empat dataset fitur URL/halaman: tolok ukur 2015–2017, PhiUSIIL 2023, URL-Phish 2026, LegitPhish 2025; pembagian 60:20:20 dengan seed 42 di dalam setiap dataset	Replikasi pipeline yang sama pada setiap dataset secara terpisah, bukan transfer beku lintas korpus; tuning hanya pada validasi dan partisi uji disentuh sekali; ambang dipilih pada validasi; tanpa pemisahan berbasis waktu	Tidak menjalankan transfer lintas korpus berpasangan; evaluasi lintas dataset bersifat deskriptif dan tidak diuji signifikansinya; analisis penjelasan berbasis SHAP

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Sumber	Korpus, domain, dan unit pembagian	Desain waktu, adaptasi, dan ambang	Batas pemakaian
Alam et al. [26]	SoK atas 55 pendekatan deteksi situs phishing berbasis AI; bukan evaluasi empiris pada satu korpus	Kerangka penilaian empat metrik fungsionalitas dan tiga metrik keamanan atas literatur; tidak menjalankan model	Tidak menghasilkan angka kinerja baru; dipakai sebagai bukti bahwa evaluasi berbasis akurasi meninggalkan blind spot
Rashid et al. [27]	Tiga dataset URL: ISCX, EBBU, dan HP; setiap dataset dibagi 60:20:20 secara acak di dalam dataset itu sendiri	Uji transfer antarpasangan dataset dengan empat model sumber (URLNet, URLTran, CatchPhish, PhishRF), lalu kerangka Unsupervised Domain Adaptation untuk menyelaraskan fitur; tanpa pemisahan berbasis waktu dan tanpa ambang operasional	Tidak melakukan evaluasi temporal; tidak memilih ambang pada validasi; korpus tidak mencakup PhiUSIIL maupun PhreshPhish; pendekatannya mengadaptasi, bukan membekukan model
Henry et al. [32]	Dua dataset dengan nol tumpang tindih fitur: UCI (11.055 sampel, 31 fitur) dan PhiUSIIL (235.795 sampel, 56 fitur)	Harmonisasi PCA ke 20 dimensi dan fusi probabilitas berbobot; transfer satu arah UCI→PhiUSIIL; tanpa pemisahan berbasis waktu dan tanpa ambang yang dipilih pada validasi	Bukan transfer beku dua arah; akurasi lintas dataset dilaporkan setelah harmonisasi fitur, sehingga tidak mengukur portabilitas tanpa penyesuaian
Axelsson [21]; Saito dan Rehmsmeier [22]; Trad dan Chehab [23]	Sistem deteksi, klasifikasi tidak seimbang, dan model bahasa besar	Prinsip base rate dan precision-recall; arah model bahasa besar tidak diuji di sini	Prinsip umum; bukan estimasi pada korpus ini

1.2 Tinjauan Tematik: Waktu, Representasi, dan Ambang Operasional

Literatur evaluasi keamanan berbasis pembelajaran mesin merumuskan dua sumber bias yang relevan bagi penelitian ini. Bias spasial muncul ketika distribusi data latih dan uji tidak mewakili kondisi penerapan, sedangkan bias temporal muncul ketika pemisahan waktu tidak menghormati urutan kejadian [13]. Kerangka TESSERACT menunjukkan bahwa keduanya dapat menaikkan skor secara sistematis: F1 yang dilaporkan mendekati 0,99 pada klasifikasi malware sebagian berasal dari rancangan eksperimen, bukan dari kemampuan model [13]. Pada penerapan, penurunan kinerja akibat perubahan distribusi dipantau melalui deteksi drift konsep yang membandingkan sampel penerapan dengan sampel latih [14], dan evaluasi ulang terhadap pendekatan tersebut menunjukkan bahwa kesimpulan tentang drift bergantung pada protokol evaluasi serta pada cara model menolak prediksi yang berisiko [15]. Ketiga temuan itu tidak memindahkan besaran efek ke domain phishing URL; yang dipindahkan adalah prinsip bahwa unit pembagian, urutan waktu, dan definisi kohort harus dinyatakan sebagai bagian dari klaim.

Pada domain phishing URL, laporan kinerja tinggi merupakan hal yang umum. Tinjauan sistematis atas 80 makalah mengelompokkan pendekatan deteksi situs phishing menjadi berbasis daftar, kemiripan visual, heuristik, pembelajaran mesin, dan pembelajaran mendalam [16]. Pendekatan hibrida berbasis fitur URL melaporkan kinerja deteksi yang sangat tinggi pada korpus masing-masing [17], pendekatan ringan berbasis fitur leksikal dan metadata dilaporkan tetap berdaya pada kondisi evasi sederhana [18], dan studi kasus pada URL login menunjukkan bahwa komposisi himpunan uji mengubah laju positif palsu secara material [19]. Model berbasis LSTM dengan fitur karakter dan TF-IDF pada URL mentah juga melaporkan kinerja tinggi tanpa menggunakan fitur halaman [20]. Protokol evaluasi terbaru pada korpus PhiUSIIL melaporkan akurasi 0,9962 sampai 0,9984 pada himpunan uji domain-disjoint untuk empat keluarga model, dan protokol yang sama juga memuat evaluasi eksternal lintas sumber pada Subbagian 4.6 artikel tersebut; kinerjanya turun tajam ketika URL dimutasi secara realistis [24]. Studi terbaru juga menunjukkan bahwa robustness terhadap serangan adversarial adalah sumbu terpisah yang tidak tercakup oleh akurasi bersih [31]; sumbu itu tidak diuji dalam artikel ini. Pola semacam ini konsisten dengan saturasi benchmark yang bersifat deskriptif: ketika banyak model berbeda mencapai skor hampir identik pada satu korpus, daya pembeda pada konfigurasi yang dievaluasi tampak terbatas untuk pertanyaan pemilihan model, dan artikel ini tidak menetapkan penyebabnya. Studi independen terbaru memperkuat pola ini pada korpus yang sama: dengan empat dataset yang mencakup PhiUSIIL, Ahmed et al. [25] juga melaporkan kinerja mendekati plafon pada PhiUSIIL dan menandainya sebagai peringatan, karena satu fitur, yaitu URLSimilarityIndex, mendominasi atribusi SHAP dan dinilai lebih dekat ke proksi label berbasis kemiripan daripada indikator phishing yang independen. Kesimpulan itu selaras dengan audit yang dilaporkan di sini, tetapi protokolnya berbeda: [25] mereplikasi pipeline yang sama pada setiap dataset secara terpisah, bukan mentransfer model yang dibekukan dari satu korpus ke korpus lain, dan tidak melakukan pemisahan berbasis waktu.

Kegagalan portabilitas lintas korpus bukan temuan baru pada domain ini, dan artikel ini tidak mengklaimnya sebagai demikian. Studi lintas dataset menunjukkan bahwa keandalan fitur tidak otomatis berpindah antar korpus [9]; evaluasi leave-one-family-out pada korpus yang sama menunjukkan transfer yang buruk ke keluarga serangan yang tidak terlihat [24]; Rashid et al. [27] melaporkan bahwa empat model deteksi URL terkemuka turun 10–32% F1 ketika diuji pada dataset yang berbeda dari dataset latihnya, lalu memulihkan sekitar 0,06 F1 melalui Unsupervised Domain Adaptation; dan Henry et al. [32] melaporkan bahwa akurasi lintas dataset antara UCI dan PhiUSIIL hanya 57,4% tanpa penyesuaian, lalu naik ke 94,4% setelah fitur diharmonisasikan dengan PCA dan prediksi difusikan secara berbobot. Ketiga hasil itu menegaskan bahwa masalahnya nyata dan bahwa literatur telah mengembangkan cara MENGATASINYA. Yang membedakan artikel ini adalah apa yang diukur: [27] dan [32] mengadaptasi atau menyelaraskan representasi agar model dapat berpindah, sedangkan di sini model, ekstraktor, urutan fitur, dan ambang dibekukan sepenuhnya tanpa penyesuaian apa pun, dan penerapannya dilakukan dua arah. Yang dilaporkan karena itu bukan sejauh mana adaptasi dapat memulihkan kinerja, melainkan batas portabilitas apa adanya pada konfigurasi yang diuji. Selain itu baik [27] maupun [32] tidak mengevaluasi sumbu temporal maupun ambang yang dipilih pada validasi, sedangkan kedua sumbu itu diukur di sini pada pasangan korpus PhiUSIIL dan PhreshPhish. Kontribusi artikel ini pada sumbu tersebut bersifat diagnostik: bukti empiris yang dapat diaudit tentang di mana dan seberapa dalam transfer gagal, dibaca bersama evaluasi temporal dalam korpus dan trade-off ambang yang dipilih pada validasi; bukan pengajuan metode adaptasi baru.

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 3
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Tinjauan sistematis terbaru atas 55 pendekatan deteksi situs phishing berbasis AI menyimpulkan bahwa evaluasi yang berpusat pada akurasi meninggalkan blind spot: tidak ada studi yang memenuhi seluruh persyaratan fungsionalitas dan keamanan, sebagian besar pendekatan tidak memiliki mekanisme untuk menghadapi drift, dan banyak berisiko menaikkan alarm palsu karena pengujian pada halaman benign yang beragam masih terbatas [26]. Tinjauan itu merekomendasikan evaluasi yang sadar waktu dan pengujian benign yang lebih beragam. Kedua rekomendasi tersebut adalah dua sumbu yang diuji secara empiris dalam artikel ini, yaitu evaluasi temporal dalam-korpus dan pelaporan FPR benign beserta taksonomi galat; artikel ini tidak mengklaim memenuhi seluruh persyaratan pada tinjauan tersebut.

Pada sisi operasional, literatur sistem deteksi telah lama menunjukkan bahwa ketika peristiwa yang dicari jarang, laju positif palsu yang kecil tetap menghasilkan proporsi alarm palsu yang besar di antara seluruh alarm [21]. Untuk data yang tidak seimbang, analisis precision-recall lebih informatif daripada ROC karena sensitif terhadap prevalensi kelas positif [22]. Karena itu artikel ini melaporkan FPR bersama proyeksi nilai prediksi positif pada prevalensi asumsi, dan memperlakukan proyeksi tersebut sebagai skenario aritmetika, bukan pengamatan penerapan. Analisis empiris atas metrik klasifikasi tidak seimbang menyarankan pelaporan beberapa metrik yang berbeda secara mendasar sekaligus, dan secara khusus menyebut kurva precision-recall serta koefisien korelasi Matthews sebagai pilihan yang lebih baik daripada F1 atau geometric mean ketika label berpotensi berisik [30].

Perkembangan mutakhir juga mencakup penggunaan model bahasa besar, dengan perbandingan antara rekayasa prompt dan fine-tuning untuk deteksi URL phishing [23]. Arah tersebut tidak diuji dalam artikel ini karena kebutuhan utamanya adalah rantai evaluasi yang dapat dibekukan dan diaudit pada tingkat artefak, bukan pemilihan keluarga model.

Kesenjangan yang dituju karena itu bukan ketiadaan penelitian deteksi phishing, melainkan belum terjawabnya pertanyaan yang lebih sempit pada artefak penelitian ini: apakah kesimpulan PhiUSIIL tetap sama setelah unit pembagian, kelompok fitur, dan evaluasi temporal dibedakan dalam satu rantai bukti yang dapat diaudit. Jawabannya dibatasi pada dua korpus dan desain yang benar-benar diuji.

PhiUSIIL [1] dipilih karena ukurannya besar dan menyediakan fitur URL, host, serta konten; sifat ini memungkinkan audit keterpulihan label dan pemisahan entitas. PhreshPhish [2] menyediakan URL mentah dan penanda waktu untuk evaluasi temporal dalam-korpus serta transfer lintas-korpus. Partisi temporal yang digunakan di sini telah diperiksa dalam pekerjaan eksploratif sebelumnya dan bukan holdout buta atau prospektif.

Penelitian ini menguji lima pertanyaan. RQ1 menilai selisih deskriptif antara pembagian acak dan *site-disjoint* pada PhiUSIIL. RQ2 mengukur perubahan ketika enam fitur konten dihapus sebagai satu kelompok. RQ3 mengukur kinerja A2 pada evaluasi temporal dalam-korpus PhreshPhish. RQ4 menguji portabilitas *zero-shot* model A2 tanpa retraining, kalibrasi, atau penyetelan ambang pada dua arah: dilatih pada PhiUSIIL dan diuji pada PhreshPhish, serta dilatih pada PhreshPhish dan diuji pada PhiUSIIL. RQ5 mengukur trade-off ambang yang dipilih hanya pada validasi serta konsentrasi galat pada kategori URL yang telah ditentukan.

Kebaruan yang diklaim bersifat evaluatif, bukan arsitektural: penelitian ini membandingkan kinerja benchmark, evaluasi temporal dalam-korpus, dan transfer lintas-korpus, lalu mengaitkan analisis tersebut dengan pemilihan ambang dan deskripsi galat. Hasil PhiUSIIL konsisten dengan saturasi benchmark deskriptif; penelitian ini tidak menetapkan mekanismenya. Artikel ini tidak mengklaim protokol atau model baru, kinerja *state of the art*, bukti kausal tentang drift, deteksi *zero-day*, atau kesiapan deployment.

Kontribusi yang diklaim terbatas pada empat butir berikut.

1. Audit keterpulihan label dan *saturasi benchmark deskriptif* pada PhiUSIIL, dilengkapi pembagian *site-disjoint* dan ablasi kelompok A1−A0 berpasangan pada domain.
2. Evaluasi temporal A2 dalam PhreshPhish dan uji transfer *zero-shot* dua arah, PhiUSIIL→PhreshPhish dan PhreshPhish→PhiUSIIL, menggunakan ekstraktor, urutan fitur, model, dan ambang yang dibekukan; desain ini secara langsung menguji portabilitas lintas-korpus.
3. Evaluasi ambang operasional yang memilih empat aturan hanya pada periode validasi dan menerapkannya sekali pada kohort uji temporal yang tidak berubah, lengkap dengan proyeksi PPV pada prevalensi rendah.
4. Taksonomi galat deskriptif yang diturunkan dari prediksi tersimpan, disertai dukungan kategori, interval Wilson, contoh yang direduksi, dan batas interpretasi deskriptif.

Sisa artikel disusun sebagai berikut. Bagian 2 menjabarkan data, protokol, konfigurasi fitur, model, dan metrik. Bagian 3 menyajikan hasil audit, perbandingan protokol, ablasi, evaluasi temporal, dan pembahasan. Bagian 4 merangkum kesimpulan beserta batasannya. Bagian 5 memuat pernyataan penulis.

2. METODOLOGI PENELITIAN

2.1 Tahapan Penelitian

Penelitian ini menggunakan pendekatan eksperimen kuantitatif dengan empat tahap: (1) pengumpulan dan pembersihan data; (2) konstruksi protokol evaluasi dengan pemisahan registrable domain; (3) pelatihan dan evaluasi model; (4) analisis kesenjangan akurasi–deployment. Seluruh artefak eksperimen mencatat konfigurasi dan seed untuk replikasi, dan setiap angka yang dilaporkan pada Bagian 3 berasal dari berkas hasil yang tersimpan, bukan dari pengukuran ulang secara manual.

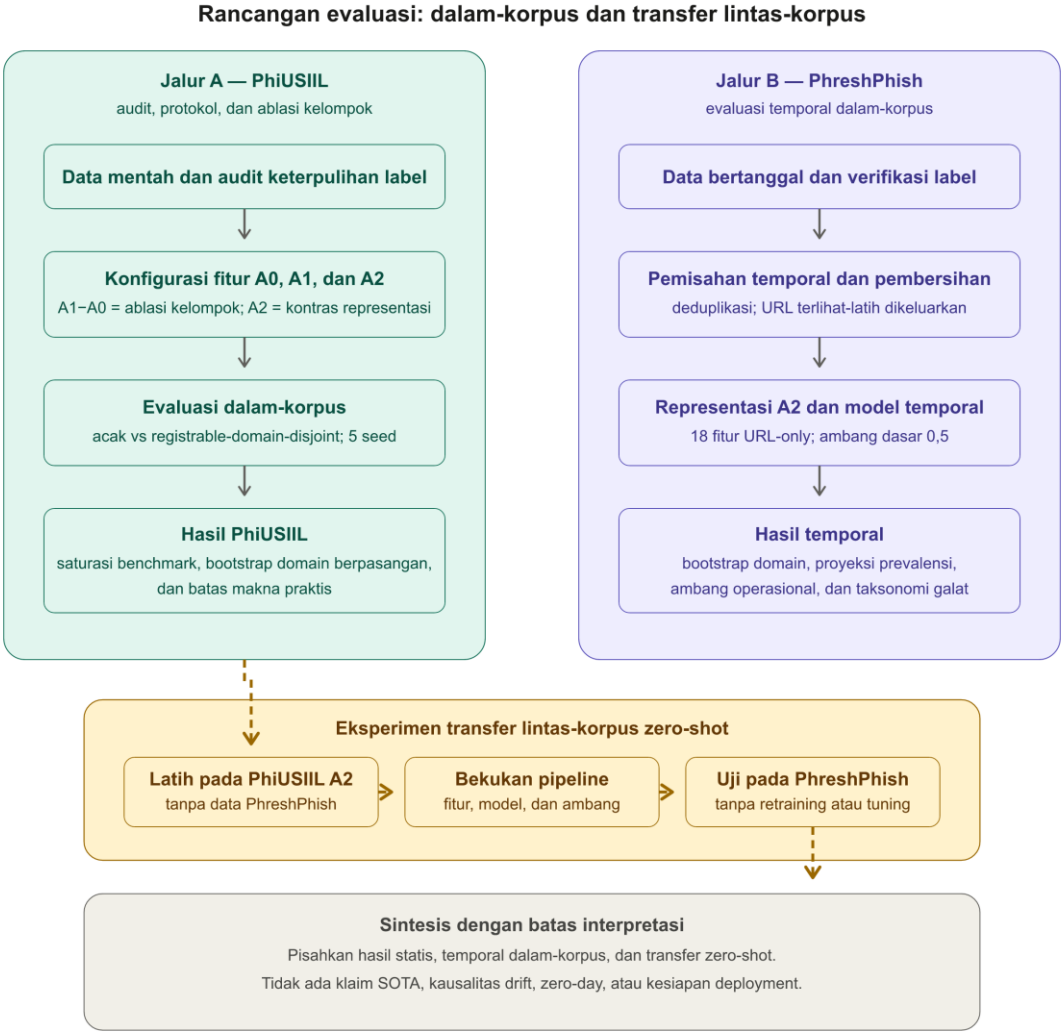
Jumlah kecocokan model utama yang dilaporkan adalah 90 kecocokan terpilih: 60 kecocokan benchmark PhiUSIIL, 10 kecocokan evaluasi temporal PhreshPhish, 10 kecocokan transfer lintas-korpus arah maju (2 model × 5 seed), 5 kecocokan LightGBM untuk evaluasi ambang operasional, dan 5 kecocokan LightGBM untuk transfer arah balik pada eksperimen 9. Angka 90 adalah cakupan kecocokan yang dipilih untuk dilaporkan, bukan seluruh kecocokan yang pernah dieksekusi: arm

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 4
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

temporal 10 kecocokan dilaporkan sekali, sedangkan rerun paritas 10 kecocokan yang identik secara metrik tidak dihitung. Empat run diagnostik 10 kecocokan non-final dengan metrik berbeda, uji paritas pra-penerbangan, uji waktu tunggal, dan dua pemeriksaan asap non-final yang tidak menyelesaikan matriks penuh juga tidak dihitung. Pipeline evaluasi versi awal tidak menyumbang kecocokan pada angka ini: keluarannya hanya metrik agregat tanpa prediksi per baris, dan cabang temporalnya berhenti sebagai stub/uji kering tanpa pemberian skor. Taksonomi galat tidak melatih model baru.

Gambar 1 merangkum desain penelitian. Jalur kiri mengaudit PhiUSIIL dan menghasilkan model sumber A2. Jalur kanan menjalankan evaluasi temporal, pemilihan ambang, dan analisis galat pada PhreshPhish. Jembatan di tengah adalah uji *zero-shot*: pipeline A2 dibekukan setelah pelatihan PhiUSIIL lalu diterapkan pada kohort uji PhreshPhish tanpa penyesuaian target.



Gambar 1. Pipeline audit generalisasi. Jalur yang digambarkan adalah arm transfer arah maju: ekstraktor A2, urutan 18 fitur, model, dan ambang 0,5 dibekukan setelah pelatihan pada PhiUSIIL, dan PhreshPhish hanya digunakan sebagai target evaluasi tanpa retraining, kalibrasi, atau pemilihan ambang berbasis target. Arm arah balik (PhreshPhish→PhiUSIIL) dijalankan pada eksperimen 9 dan tidak digambarkan di sini. Jalur temporal dan ambang PhreshPhish merupakan eksperimen terpisah dan tidak digunakan untuk mengadaptasi model transfer.

2.2 Data

PhiUSIIL [1] memuat 235.795 baris dan 56 kolom. Pada sumber, label legitim dikodekan 1 (134.850 baris) dan phishing 0 (100.945 baris); tidak ada kolom kosong. Pembersihan menghapus 425 duplikat persis berdasarkan pasangan (URL, label), tanpa menemukan URL yang berkonflik label, sehingga tersisa 235.370 baris. Analisis E5 saat ini memetakan label hasil pembersihan menjadi phishing=1 dan legitim=0. Tidak ada hasil metrik E3 yang digunakan sebagai metrik positif-phishing dalam artikel ini.

Pembersihan membuang tepat empat kolom sesuai daftar DROP_COLS pada notebook pembersihan, yaitu `FILENAME`, URLSimilarityIndex, DomainTitleMatchScore, dan URLTitleMatchScore; FILENAME merupakan artefak pengumpulan, sedangkan tiga lainnya dibuang berdasarkan penyaringan konservatif atas asosiasi univariat teramati dengan label, dengan AUC tunggal 0,9961, 0,7923, dan 0,7707. Di antara ketiga kolom yang dibuang itu, hanya `URLSimilarityIndex` yang berada dekat plafon AUC. Dua kolom ber-AUC sangat tinggi lainnya, yaitu `LineOfCode` (0,9903) dan `NoOfExternalRef`

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

(0,9880), **tidak** dibuang dan tetap berada dalam konfigurasi acuan: skema parquet hasil pembersihan memuat keduanya, dan 47 dari 52 kolom sumber tersisa digunakan sebagai fitur A0. AUC ini menggambarkan separabilitas dan tidak membuktikan derivasi fitur dari label. Nilai AUC ditampilkan hingga empat desimal; pernyataan "di atas 0,988" karena itu dibaca sebagai sekitar 0,988 atau lebih, bukan sebagai perbandingan nilai terbulatkan.

Dataset PhreshPhish, yang saat ini dideskripsikan dalam sebuah preprint [2], digunakan untuk dua peran yang tidak dicampur: evaluasi temporal dalam-korpus dan target transfer lintas-korpus. Korpus ini dikumpulkan melalui pipeline, vendor, dan jendela waktu yang berbeda dari PhiUSIIL. Evaluasi temporal melatih model pada periode awal PhreshPhish, sedangkan transfer lintas-korpus dijalankan dua arah: arah maju melatih model hanya pada PhiUSIIL dan menggunakan kohort uji PhreshPhish sebagai target tanpa adaptasi, dan arah balik melatih model hanya pada blok fit PhreshPhish dengan deduplikasi string URL persis lalu menguji pada PhiUSIIL tanpa adaptasi. Perbandingan tetap tidak mengisolasi penyebab pergeseran distribusi.

2.3 Protokol Pembagian Data

Dua protokol dibandingkan pada PhiUSIIL.

Pembagian acak (URL-level). Baris dibagi secara acak tanpa memperhatikan domain. Protokol ini mewakili praktik yang dominan dalam literatur. Ukuran himpunan uji adalah 47.074 baris untuk setiap seed.

Pembagian site-disjoint (registrable-domain level). Seluruh baris yang berbagi satu registrable domain ditempatkan pada sisi yang sama. Domain dihitung menggunakan kebijakan sufiks bawaan `tldextract`, yaitu daftar Public Suffix List publik. Ukuran himpunan uji bervariasi antarseed.

Satu batasan protokol perlu dinyatakan di muka. Kebijakan sufiks bawaan memperlakukan penyewa berbeda pada platform hosting bersama sebagai bagian dari satu registrable domain. Sebagai contoh, `web.app` menampung 5.718 baris, `firebaseapp.com` 5.546 baris, `repl.co` 3.746 baris, `weeblysite.com` 3.079 baris, `ipfs.io` 1.552 baris, dan `workers.dev` 1.423 baris. Pembagian *site-disjoint* karena itu memisahkan **registrable domain**, bukan penyewa. Batasan yang sama berlaku pada subset tanpa tumpang tindih ketat berbasis kunci registrable domain: penyewa independen pada platform bersama dapat memiliki kunci yang sama, sehingga pengelompokan ini tidak membuktikan independensi pada tingkat penyewa maupun identitas kampanye/operator yang sama. Pemeriksaan pada subset tanpa tumpang tindih ketat diperlakukan sebagai analisis sensitivitas atas prediksi yang tersimpan, bukan sebagai uji independen.

Pada evaluasi temporal PhreshPhish, pembagian dilakukan berdasarkan waktu: model dilatih pada periode lebih awal dan diuji pada periode lebih akhir, dengan unit resampling berupa registrable domain.

2.4 Konfigurasi Fitur

Tiga konfigurasi fitur digunakan. Tabel 2 merangkum ketiganya.

Tabel 2. Konfigurasi fitur A0, A1, dan A2 yang dibandingkan.

Konfigurasi	Jumlah fitur	Sumber	Peran dalam desain
A0	47	Kolom terhitung pada `phiusiil_clean.parquet`	Konfigurasi acuan
A1	41	A0 dikurangi enam fitur konten	Ablasi kelompok terkontrol
A2	18	Dihitung deterministik per URL dari URL mentah menggunakan ekstraktor bersama; tidak menyalin nilai sumber yang telah dihitung sebelumnya.	Representasi URL-only; juga dipakai pada PhreshPhish

Enam fitur yang dihapus untuk membentuk A1 adalah LineOfCode, NoOfImage, NoOfCSS, NoOfJS, NoOfSelfRef, dan NoOfExternalRef. Karena keenamnya dihapus bersama, A1 membandingkan konfigurasi tanpa kelompok fitur konten dengan A0, bukan mengisolasi efek masing-masing fitur; rancangan ini tidak menetapkan kontribusi kausal. Rancangan ini tidak mengidentifikasi fitur mana di dalam kelompok yang bertanggung jawab atas perubahan.

A2 adalah kontrak terurut 18 fitur leksikal dan host yang dihitung deterministik per URL menggunakan ekstraktor URL mentah bersama: `URLLength`, `DomainLength`, `TLDLength`, `NoOfSubDomain`, `NoOfObfuscatedChar`, `ObfuscationRatio`, `NoOfLettersInURL`, `LetterRatioInURL`, `NoOfDegitsInURL`, `DegitRatioInURL`, `NoOfEqualsInURL`, `NoOfQMarkInURL`, `NoOfAmpersandInURL`, `NoOfOtherSpecialCharsInURL`, `SpacialCharRatioInURL`, `IsHTTPS`, `HasObfuscation`, dan `IsDomainIP`. Kesamaan kontrak dan ekstraktor tidak membuktikan kesamaan nilai A2 dengan kolom A0 terhitung sebelumnya yang memiliki nama serupa. Karena himpunan fitur dan representasinya berubah bersama, A2−A0 adalah kontras representasi, bukan ablasi satu faktor atau identitas dengan pengukuran sumber.

A0 dan A1 menggunakan fitur tersimpan yang diwarisi dari dataset hasil pembersihan. Untuk fitur statistik dan fitur halaman/konten tersimpan, termasuk TLDLegitimateProb, URLCharProb, dan CharContinuationRate, producer hulu, populasi referensi, waktu komputasi, dan ketergantungan terhadap label belum diketahui. Probe target-encoding historis membuktikan kebocoran pada implementasi probe tersebut saja, yang menghitung rerata turunan-label sebelum pemisahan lanjutan. Bukti yang tersedia tidak menetapkan bahwa probe itu menghasilkan nilai A0/A1 yang tersimpan saat ini; fitting estimator saat ini pada baris latih juga tidak mensertifikasi provenance fitur hulu sebagai bebas kebocoran. A2 tidak mencakup TLDLegitimateProb atau URLCharProb.

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 6
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

2.5 Model dan Pelatihan

Dua model gradient boosting digunakan: LightGBM dan XGBoost. Keduanya dipilih sebagai pembanding karena telah digunakan dan dibandingkan dalam studi deteksi phishing URL [10]; pilihan ini juga mempertimbangkan biaya komputasi yang memungkinkan pengulangan lima seed, dan pertimbangan biaya tersebut merupakan keputusan desain studi ini, bukan klaim yang bersumber dari [10]. Setiap kombinasi protokol, konfigurasi, dan model dilatih dengan lima seed (13, 42, 777, 2024, 31415). Pada evaluasi temporal PhreshPhish, hasil XGBoost identik pada kelima seed karena prosedur histogram deterministik tanpa subsampling; hal ini dilaporkan sebagai keterbatasan variabilitas, bukan sebagai bukti kestabilan yang lebih tinggi.

Ambang keputusan tetap 0,5 pada benchmark PhiUSIIL, evaluasi temporal utama, dan transfer lintas-korpus. Eksperimen operasional tambahan pada PhreshPhish membandingkan ambang 0,5 dengan tiga ambang yang dipilih hanya dari periode validasi; seluruh ambang kemudian dibekukan sebelum evaluasi pada periode uji.

Konfigurasi model dan lingkungan dicatat untuk keterlacakan. LightGBM dilatih dengan 300 estimator, learning rate 0,05, dan 63 daun; XGBoost dilatih dengan 300 estimator, learning rate 0,05, max_depth 8, eval_metric logloss, dan tree_method hist. Tidak ada penyetelan hiperparameter pada korpus target. Lingkungan eksperimen menggunakan LightGBM 4.7.0, scikit-learn 1.9.1, tldextract 5.4.0, NumPy 2.5.3, dan pandas 3.1.0, dengan snapshot Public Suffix List ber-SHA-256 b69315c085d53972724b8f2df111ffc329b0c84fe0a47d62c8c91655cc774a38.

2.6 Metrik dan Analisis Statistik

Untuk analisis E5–E8 saat ini, label dipetakan menjadi legitim=0 dan phishing=1; phishing adalah kelas positif, dan FPR benign dihitung terhadap kelas legitim. Metrik utama adalah F1 kelas phishing, dilengkapi recall, precision, FPR benign, MCC, dan akurasi. Metrik E3 lama tidak digunakan sebagai metrik positif-phishing: E3 memakai pengodean sumber PhiUSIIL (legitim=1), sehingga precision, recall, F1, dan kolom probabilitas kelas 1 bawaan E3 bukan metrik positif-phishing.

Interval kepercayaan 95 % untuk rata-rata lintas seed dihitung dengan distribusi t (df = 4) dari lima metrik per seed, dan tersedia sebagai seed_t_intervals.csv pada folder keluaran eksperimen 5; variasi yang tercakup juga meliputi perubahan partisi pada benchmark. Untuk perbandingan berpasangan A1−A0, digunakan *paired bootstrap* pada unit registrable domain dengan 1.000 replikasi dan seed bootstrap 42; jumlah domain pada himpunan uji *site-disjoint* adalah 35.100. Untuk evaluasi temporal, interval dihitung dengan *bootstrap* pada unit registrable domain, 1.000 replikasi, dan seed RNG bootstrap 42, diterapkan pada prediksi model seed 13; angka 13 pada Tabel 6 menandai seed model, bukan seed RNG bootstrap. Kembali ke perbandingan A1−A0: titik estimasinya adalah nilai model seed 42, bukan rerata lima seed pada Tabel 4; seed 42 di sini berperan sebagai seed model, sedangkan seed 42 pada bootstrap berperan sebagai seed RNG resampling. Karena itu selisih pada Tabel 5 dan selisih rerata pada Tabel 4 memang berbeda dan tidak boleh dibandingkan langsung.

Interval yang dilaporkan di sini menggambarkan ketidakpastian sampling domain pada satu model tetap dan satu kohort tertentu. Interval tersebut **bukan** jaminan generalisasi temporal.

Proyeksi prevalensi dihitung secara aritmetika dari TPR dan FPR terukur menggunakan bentuk standar nilai prediksi positif, $PPV = \pi \cdot TPR / (\pi \cdot TPR + (1-\pi) \cdot FPR)$, untuk nilai prevalensi π yang diasumsikan. Proyeksi ini adalah skenario, bukan perilaku deployment yang diamati. Bentuk proyeksi ini merupakan penerapan langsung argumen base-rate pada sistem deteksi [21], dan untuk data yang tidak seimbang analisis precision-recall lebih informatif daripada ROC [22].

2.7 Transfer Lintas-Korpus Zero-Shot

Eksperimen ini menguji RQ4 dengan kontrak A2 yang sama—ekstraktor URL bersama dan skema terurut 18 kolom—pada sumber dan target. Kesamaan kontrak tidak membuktikan kesamaan nilai A2 dengan nilai sumber terhitung sebelumnya yang bernama serupa. Pipeline saat ini memetakan phishing sebagai kelas 1 dan menggunakan probabilitas kelas tersebut; hal ini tidak memvalidasi polaritas metrik E3 lama. Ekstraksi 18 fitur, urutan kolom, parameter model, dan label positif phishing=1 diambil dari artefak tersimpan; manifest keluaran eksperimen transfer dicocokkan untuk urutan fitur dan ambang 0,5. Model LightGBM dan XGBoost dilatih hanya pada fold pelatihan pembagian acak PhiUSIIL seed 42 dan dievaluasi pada fold uji sumber sebagai referensi dalam-domain. Tiga istilah dipakai konsisten di seluruh naskah: dalam-korpus berarti evaluasi temporal latih-lalu-uji di dalam PhreshPhish; dalam-sumber berarti evaluasi pada blok uji korpus sumber di dalam eksperimen transfer; dan dalam-domain berarti evaluasi referensi pada PhiUSIIL. Model yang sama kemudian diterapkan pada 168.035 baris kohort uji temporal PhreshPhish tanpa fitting, kalibrasi, normalisasi, pemilihan fitur, atau penyetelan ambang menggunakan data target. Ambang tetap 0,5.

Lima seed model (13, 42, 777, 2024, 31415) mengukur variasi prosedur pelatihan; seluruhnya menggunakan partisi sumber dan target yang sama. Seed 42 ditetapkan sebagai hasil utama. Ketidakpastian target dihitung dengan 1.000 replikasi bootstrap pada unit registrable domain dengan seed RNG bootstrap 42, mencakup 65.288 registrable domain. Karena waktu, vendor, dan populasi berbeda bersama korpus, eksperimen ini menguji portabilitas pada pasangan korpus tersebut, bukan mengidentifikasi faktor penyebab kegagalan transfer.

2.8 Pemilihan Ambang Berbasis Validasi

Eksperimen RQ5 menggunakan LightGBM/A2 pada PhreshPhish dengan tiga blok waktu yang tidak tumpang tindih: fit 2 Juli 2024–30 Juni 2025 (372.213 baris), validasi 1 Juli–7 September 2025 (125.146 baris), dan uji 8 September–16 Desember 2025 (168.035 baris). Deduplikasi dan pembersihan dilakukan sebelum pembentukan blok; hash URL antarblok tidak tumpang tindih. Kohort uji sama persis dengan evaluasi temporal utama dan diverifikasi melalui `row_id`, label, serta hash URL; kohort ini telah diperiksa dalam pekerjaan eksploratif sebelumnya dan bukan holdout buta atau prospektif. Model

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

pada eksperimen ini dilatih ulang hanya pada blok fit, sedangkan evaluasi temporal pada Subbagian 3.5 memakai model yang dilatih pada seluruh blok pra-cutoff, yaitu periode fit dan validasi (497.359 baris). Baris uji identik, tetapi modelnya berbeda, sehingga metrik pada ambang 0,5 pada Tabel 8 tidak identik dengan Tabel 6 dan kedua tabel itu tidak boleh dibaca sebagai satu kecocokan yang sama.

Empat aturan dibandingkan: ambang bawaan 0,5; ambang terkecil yang mencapai FPR benign validasi ≤1%; ambang terkecil yang mencapai FPR validasi ≤0,5%; dan ambang yang memaksimalkan F1 validasi dengan tie-break menuju ambang lebih kecil. Aturan dipilih terpisah pada lima seed, dibekukan, lalu diterapkan sekali pada uji. Tidak ada label atau skor uji yang digunakan dalam pemilihan. Proyeksi PPV pada prevalensi 1% dan 5% menggunakan TPR dan FPR uji sebagai asumsi transfer, bukan pengukuran pada prevalensi tersebut.

2.9 Taksonomi Galat Empiris

Taksonomi galat menggunakan prediksi tersimpan LightGBM seed 13 dari evaluasi temporal utama pada ambang 0,5. Tidak ada model baru dan tidak ada penyetelan berbasis galat. Kategori ditentukan secara deterministik dari URL: panjang, rasio digit, kedalaman subdomain perkiraan, skema HTTPS, query, IP/punycode, daftar pendek pemendek URL dan platform hosting, token leksikal, bulan, bahasa, serta status domain terlihat/tidak terlihat. Setiap kategori melaporkan dukungan, FP/FN, laju bersyarat pada kelas, dan interval Wilson 95%; kategori dengan n<30 ditandai dukungan rendah. Temuan ini bersifat eksploratif dan deskriptif karena kategori saling tumpang tindih serta berkorelasi dengan prevalensi, bulan, dan panjang URL. Nilai interval Wilson per kategori dihitung dari penyebut di dalam kategori dan tersimpan pada berkas taksonomi galat (kolom batas bawah dan batas atas); Tabel 9 menampilkan proporsi titik saja.

3. HASIL DAN PEMBAHASAN

3.1 Audit Keterpulihan Label dan Repetisi Domain pada PhiUSIIL

Audit menemukan tiga kolom dengan AUC tunggal mendekati plafon. `URLSimilarityIndex` mencapai AUC 0,9961 terhadap label, `LineOfCode` 0,9903, dan `NoOfExternalRef` 0,9880. Ketiganya mampu mengurutkan kelas hampir sempurna tanpa bantuan model apa pun. Kolom keempat dan kelima, `DomainTitleMatchScore` (0,7923) dan `URLTitleMatchScore` (0,7707), masih membawa sinyal kuat tetapi tidak berada pada tingkat plafon; keduanya dibuang berdasarkan keputusan desain yang konservatif. Kolom `NoOfSelfRedirect` (0,5152) dan `IsDomainIP` (0,5032) hampir tidak membawa sinyal tunggal dan dipertahankan.

Implementasi menghapus `URLSimilarityIndex` tetapi mempertahankan `LineOfCode` dan `NoOfExternalRef` dalam A0. Dengan demikian, konfigurasi acuan 47 fitur memuat dua kolom dengan AUC tunggal sekitar 0,988 atau lebih, yang menunjukkan separabilitas tinggi pada korpus berlabel. Hal ini tidak menunjukkan bahwa salah satu kolom diturunkan dari label atau menyebabkan hasil model yang mendekati plafon. Nilai F1 0,9996–0,9998 adalah hasil benchmark yang teramati; bukti yang tersedia tidak memisahkan kontribusi pemodelan, nilai fitur tersimpan, label sumber, maupun proses pengumpulan data.

Audit domain menemukan 175.509 registrable domain unik dan 636 baris alamat IP. Nilai registrable domain berulang terdapat pada 62,0 % baris phishing dan 2,6 % baris legitim. Ini adalah asimetri distribusi yang teramati; hal tersebut tidak menunjukkan bahwa label diturunkan dari identitas domain atau bahwa penyewa yang berbagi kunci platform berasal dari kampanye atau operator yang sama. Provenance fitur sumber dan label yang diperlukan untuk menetapkan hubungan tersebut tidak tersedia.

Pada pembagian acak dengan seed 42, 26,63 % baris uji berbagi registrable domain dengan baris latih; proporsinya 59,17 % pada baris uji phishing dan 2,37 % pada baris uji legitim. Ini merupakan pola tumpang tindih yang teramati, bukan bukti pengenalan oleh model, kebocoran, bias optimistis, atau inflasi kinerja. Analisis ini tidak mengisolasi kontribusi kausal paparan domain dari fitur ber-AUC tinggi yang tetap tersedia di A0. Producer hulu dan ketergantungan label fitur A0/A1 tersimpan masih belum diketahui.

3.2 Perbandingan Protokol Pembagian Data

Tabel 3 merangkum F1 kelas phishing untuk kedua protokol pada konfigurasi A0, dirata-ratakan atas lima seed, dengan model LightGBM dan XGBoost.

Tabel 3. F1 kelas phishing pada PhiUSIIL, konfigurasi A0 (47 fitur), rerata lima seed.

Model	Protokol	F1 phish	Recall	Precision	FPR benign	MCC
LightGBM	Acak	0,999826	0,999771	0,999881	0,000089	0,999696
LightGBM	Site-disjoint	0,999623	0,999422	0,999823	0,000111	0,999386
XGBoost	Acak	0,999856	0,999861	0,999851	0,000111	0,999748
XGBoost	Site-disjoint	0,999693	0,999563	0,999823	0,000111	0,999501

Selisih rerata antarprotokol berada pada rentang 0,000162 sampai 0,001178 dalam F1, bergantung pada model dan konfigurasi. Untuk A0/LightGBM selisihnya 0,000203; untuk A0/XGBoost 0,000162, dihitung dari nilai tak-terbulatkan pada summary.csv eksperimen 5. Interval kepercayaan 95 % berbasis t (df = 4) pada masing-masing protokol dihitung dan tersedia pada seed_t_intervals.csv eksperimen 5, tidak ditabulasikan dalam artikel ini; interval tersebut menunjukkan variasi lintas seed, bukan menguji selisih lintas protokol. Perbandingan antarprotokol di sini bersifat deskriptif: tidak ada uji berpasangan lintas protokol yang dijalankan karena partisi ujinya berbeda dan bukan pasangan baris yang sama. Tumpang tindih interval juga tidak diperlakukan sebagai bukti ekuivalensi.

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Ukuran partisi uji juga berbeda antarprotokol. Pembagian acak menggunakan 47.074 baris uji untuk setiap seed, sedangkan pembagian *site-disjoint* menghasilkan partisi uji yang berbeda antarseed. Rerata lima seed karena itu merata-ratakan lima partisi uji yang berbeda, bukan lima pengulangan pada partisi yang sama.

Angka pada Tabel 3 harus dibaca bersama Bagian 3.1. Pada baseline 0,9996, selisih 0,0002 dalam F1 setara dengan perubahan beberapa keputusan klasifikasi saja pada partisi uji berukuran puluhan ribu baris. Selisih tersebut kecil secara praktis; signifikansi statistik lintas protokol tidak diuji karena baris uji tidak berpasangan. Artikel ini tidak menyimpulkan bahwa protokol *site-disjoint* "memperbaiki" evaluasi dalam pengertian peningkatan kinerja model. Yang berubah adalah keabsahan klaim, bukan kemampuan model.

Studi metodologis menekankan bahwa pengaruh protokol bergantung pada unit independensi dan karakteristik dataset [3], [5], [6]. Pada PhiUSIIL, dua kolom A0 memiliki AUC tunggal sekitar 0,988 atau lebih, sementara F1 teramati mendekati satu. Pola ini konsisten dengan saturasi benchmark deskriptif, tetapi penelitian ini tidak menguji apakah fitur, konstruksi label, pengumpulan data, paparan domain, atau faktor lain menyebabkannya; interpretasi tersebut tidak boleh digeneralisasi ke korpus lain.

3.3 Metrik Operasional dan Biaya Komputasi Benchmark

F1 saja tidak memadai untuk menilai kelayakan operasional. Tabel 4 melaporkan metrik pendamping pada protokol *site-disjoint* untuk tiga konfigurasi fitur dengan LightGBM. Pembagian ini mengecualikan kunci registrable domain bersama antara data latih dan uji; hal tersebut tidak membuktikan independensi pada tingkat penyewa atau menyingkirkan semua bentuk tumpang tindih maupun kebocoran.

Tabel 4. Metrik kelas phishing pada protokol *site-disjoint*, LightGBM, rerata lima seed.

Konfigurasi	Jumlah fitur	F1 phish	Recall	Precision	FPR benign	MCC	Akurasi
A0	47	0,999623	0,999422	0,999823	0,000111	0,999386	0,999710
A1	41	0,999055	0,998583	0,999528	0,000296	0,998460	0,999270
A2	18	0,995186	0,991828	0,998569	0,000902	0,992179	0,996289

Dalam perbandingan deskriptif ini, A2 memiliki recall lebih rendah dan FPR lebih tinggi daripada A0; perbedaan tersebut tidak mengisolasi pengaruh jumlah fitur karena sumber dan representasi fiturnya juga berbeda. Dari A0 ke A2, recall turun 0,0076 poin sementara FPR naik sekitar delapan kali lipat (0,000111 menjadi 0,000902). Pada korpus dengan prevalensi phishing rendah, kenaikan FPR pada orde ini dapat berdampak lebih besar terhadap beban investigasi analis daripada penurunan recall pada orde yang sama, tetapi besaran beban yang sebenarnya bergantung pada jumlah baris benign dan phishing, prevalensi, aturan tindak lanjut, dan biaya per investigasi, yang tidak dimodelkan di sini. Perbandingan ini bersifat deskriptif dan tidak boleh dipakai untuk menyimpulkan bahwa fitur konten "lebih penting" daripada fitur URL: A0 dan A2 juga berbeda dalam sumber representasi (lihat Bagian 3.4).

Biaya komputasi dilaporkan secara terbatas. Pada evaluasi temporal PhreshPhish, waktu pelatihan LightGBM berada pada rentang 6,06 sampai 7,21 detik per kecocokan, dan waktu prediksi batch untuk 168.035 baris uji berada pada rentang 0,79 sampai 0,84 detik. Rentang tersebut berasal dari lima kecocokan seed pada artefak results_per_seed.csv dan tidak diperlakukan sebagai klaim yang portabel, karena pengukuran waktu bergantung pada perangkat keras dan beban sistem saat eksekusi. Metadata eksekusi mencatat 16 CPU logis dan konfigurasi n_jobs, tetapi jumlah thread efektif, kapasitas RAM, dan beban sistem saat eksekusi tidak dicatat; karena itu angka waktu tersebut adalah log eksekusi, bukan pembandingan biaya komputasi.

3.4 Ablasi Kelompok Fitur dan Kontras Representasi

Ablasi kelompok terkontrol dilakukan dengan membandingkan A1 terhadap A0, yaitu penghapusan enam fitur konten sebagai satu kelompok. Perbandingan dilakukan secara berpasangan pada unit registrable domain dengan 1.000 replikasi bootstrap, seed 42, dan 35.100 domain pada himpunan uji.

Tabel 5. Selisih berpasangan A1 − A0 pada protokol *site-disjoint*, 1.000 replikasi bootstrap domain. Titik estimasi memakai model seed 42; Tabel 4 menampilkan rerata lima seed.

Metrik	Model	Selisih	IK 95 % bawah	IK 95 % atas	Selang memuat nol
F1 phish	LightGBM	−0,000980	−0,001954	−0,000318	Tidak
F1 phish	XGBoost	−0,001182	−0,002225	−0,000440	Tidak
Recall phish	LightGBM	−0,001728	−0,003721	−0,000479	Tidak
Recall phish	XGBoost	−0,001728	−0,003811	−0,000406	Tidak
FPR benign	LightGBM	+0,000149	−0,0000375	+0,000369	Ya
FPR benign	XGBoost	+0,000410	+0,000149	+0,000709	Tidak
MCC	LightGBM	−0,001612	−0,003243	−0,000523	Tidak
MCC	XGBoost	−0,001944	−0,003743	−0,000711	Tidak

Pada protokol yang diuji, A1 memiliki F1 lebih rendah daripada A0, dan interval bootstrap F1 berpasangan untuk LightGBM maupun XGBoost tidak memuat nol; besar selisihnya sekitar seperseribu F1. Rancangan ini tidak menetapkan bahwa penghapusan fitur menyebabkan penurunan tersebut. Pada rata-rata partisi uji 44.213,6 baris, jumlah kesalahan A0→A1 meningkat dari 12,8 menjadi 32,2 pada LightGBM dan dari 10,4 menjadi 39,0 pada XGBoost. Ini menggambarkan perbedaan antara keterdeteksian statistik dan besar efek. Skor A0 mendekati satu pada benchmark ini, tetapi perbandingan kelompok berpasangan tersebut tidak mengidentifikasi penyebab saturasi. Konsekuensi deployment tidak dapat disimpulkan tanpa prevalensi, biaya kesalahan, dan pemilihan ambang yang relevan.

Perlu ditegaskan bahwa rancangan ini menguji kelompok fitur. Enam fitur dihapus bersamaan, sehingga tidak ada identifikasi fitur mana di dalam kelompok yang bertanggung jawab. Klaim yang sah adalah "A1 memiliki F1 sekitar 0,001

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 9
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

lebih rendah daripada A0 pada protokol site-disjoint"; rancangan ini tidak menetapkan kontribusi kausal tiap fitur maupun kelompok fitur. Untuk mengidentifikasi kontribusi per fitur diperlukan desain leave-one-feature-out terpisah, yang tidak dijalankan di sini. Selisih rerata A1−A0 lintas lima seed pada Tabel 4 untuk F1 adalah −0,000567, sedangkan selisih berpasangan model seed 42 pada Tabel 5 adalah −0,000980; keduanya sah untuk estimandnya masing-masing dan tidak saling menggantikan.

A2 menggunakan ekstraktor URL mentah bersama dengan kontrak terurut 18 fitur, sedangkan A0 menggunakan nilai sumber terhitung sebelumnya. Audit langsung menemukan kesesuaian nilai yang rendah untuk beberapa fitur bernama serupa; definisi dan sumber nilainya dapat berbeda. Selisih F1 0,004436 untuk LightGBM *site-disjoint* karena itu merupakan **kontras representasi** deskriptif, bukan efek kausal penghapusan 29 fitur. Perbandingan ini tidak memiliki interval bootstrap berpasangan dalam rancangan A1−A0. Angka 0,004436 dihitung dari nilai F1 tak-terbulatkan; selisih nilai terbulatkan yang ditampilkan pada Tabel 4 adalah 0,004437.

3.5 Evaluasi Temporal pada PhreshPhish

Evaluasi temporal menggunakan konfigurasi A2 karena konfigurasi itu dapat dihitung dari URL mentah PhreshPhish. Model dilatih pada periode lebih awal dan diuji pada periode lebih akhir yang berisi 168.035 baris (91.259 legitim dan 76.776 phishing; prevalensi phishing 0,456905). Kohort uji ini telah diperiksa dalam pekerjaan eksploratif sebelumnya.

Tabel 6. Kinerja temporal A2/LightGBM pada PhreshPhish untuk model seed 13; batas 95 % berasal dari 1.000 replikasi bootstrap pada unit registrable domain dengan RNG seed 42. Model dilatih pada seluruh blok pra-cutoff, yaitu periode fit dan validasi (497.359 baris), dengan ambang 0,5. Batas interval diambil dari bootstrap_temporal.csv eksperimen 5; berkas cluster_bootstrap_primary_seed.csv pada folder eksperimen 4 memuat interval berbeda untuk estimasi yang sama dan tidak dipakai di sini.

Metrik	Estimasi	IK 95 % bawah	IK 95 % atas
F1 phish	0,801768	0,727697	0,849621
Recall phish	0,718193	0,607697	0,798159
Precision phish	0,907356	0,895662	0,917991
FPR benign	0,061693	0,054558	0,068601
MCC	0,680632	0,574178	0,754352
Akurasi	0,837736	0,767435	0,881669

Rerata lima seed untuk F1 adalah 0,800461 dengan simpangan baku 0,001184. Hasil XGBoost identik pada kelima seed (F1 0,799629, simpangan baku 0), karena prosedur histogram deterministik tanpa subsampling; angka ini tidak boleh dibaca sebagai kestabilan yang lebih tinggi, melainkan sebagai ketiadaan variasi seed pada prosedur tersebut.

Tiga hal perlu dibaca bersama. Pertama, precision tinggi (0,907) sementara recall jauh lebih rendah (0,718). Pada periode uji dengan prevalensi phishing 45,7 %, precision tinggi sebagian merupakan konsekuensi komposisi kelas, bukan bukti kualitas model. Kedua, FPR berada pada skala persen (6,17 %), bukan pecahan persen seperti pada PhiUSIIL (0,011 %). Ketiga, komposisi kelas berubah drastis antarbulan di dalam periode uji: prevalensi phishing 13,47 % pada September 2025, 46,75 % pada Oktober, 90,08 % pada November, dan 0 % pada Desember. F1 agregat karena itu mencampur rezim yang sangat berbeda. Pada Desember 2025, yang hanya berisi 1.017 baris benign tanpa satu pun baris phishing, F1 dan recall tidak terdefinisi; FPR pada bulan itu 0,124877. Angka tersebut dilaporkan sebagai peringatan pembacaan, bukan sebagai hasil utama.

Perubahan komposisi kelas sebagian menjelaskan mengapa angka agregat tidak dapat dipakai untuk menyimpulkan tren, meskipun TPR dan FPR tidak dijamin konstan antarbulan sehingga prevalensi bukan satu-satunya faktor. Bulan dengan prevalensi 90 % menghasilkan precision sangat tinggi secara aritmetika, sedangkan bulan dengan prevalensi 13 % menghasilkan precision jauh lebih rendah pada model yang sama. Membandingkan F1 antarbulan tanpa memperhitungkan hal ini akan menghasilkan kesimpulan yang salah arah.

3.6 Kesenjangan Akurasi dan Deployment dan Proyeksi Prevalensi

Selisih F1 antara evaluasi statis terbaik (A0, *site-disjoint*, LightGBM, 0,999623) dan evaluasi temporal (A2, LightGBM, 0,800461) adalah 0,199162. Angka ini dilaporkan sebagai selisih aritmetika, bukan sebagai efek waktu. Alasannya tegas: korpus berbeda (PhiUSIIL vs PhreshPhish), fitur berbeda (A0 dengan 47 fitur terhitung vs A2 dengan 18 fitur URL), sumber representasi berbeda, komposisi kelas berbeda, dan periode pengumpulan berbeda. Tidak ada satu pun faktor yang diisolasi oleh perbandingan ini.

Lebih penting lagi, evaluasi temporal pada PhreshPhish tidak dapat dipisahkan dari faktor temporal: periode uji berasal dari waktu yang lebih akhir daripada periode latih, sehingga perbedaan kinerja antara periode awal dan akhir tidak dapat diatribusikan kepada waktu saja. Perbandingan lintas korpus PhiUSIIL–PhreshPhish membawa perancu tambahan yang berbeda sifatnya, yaitu pipeline dan vendor pengumpulan yang berbeda, dan perancu tersebut berlaku pada perbandingan lintas korpus itu, bukan pada perbandingan antarbulan di dalam PhreshPhish. Kedua jenis perancu ini bercampur dan tidak dapat dipisahkan dengan data yang tersedia. Klaim yang sah adalah "model A2 yang dilatih pada periode awal memperoleh F1 0,800 pada periode akhir korpus PhreshPhish", bukan "kinerja model menurun 20 poin karena waktu".

Implikasi operasional dipertimbangkan dengan menggabungkan FPR terukur dan prevalensi asumsi. Dari TPR PhreshPhish 0,718193 dan FPR 0,061693, proyeksi PPV aritmetika adalah 0,105218 pada prevalensi asumsi 1 % dan 0,379926 pada 5 %; angka tersebut merupakan skenario, bukan pengamatan deployment. Untuk PhiUSIIL, PPV yang dihitung pada prevalensi asumsi 1 % dari FPR terukur 0,000111 juga merupakan skenario, bukan bukti kinerja operasional. Hasil PhiUSIIL adalah pengamatan benchmark mendekati plafon; mekanismenya belum ditetapkan. Angka proyeksi tersebut konsisten dengan peringatan base-rate bahwa FPR kecil tidak menjamin proporsi alarm palsu yang kecil ketika prevalensi rendah [21], [22].

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

3.7 Transfer Lintas-Korpus Zero-Shot

Eksperimen ini menguji klaim paling langsung dalam artikel: apakah representasi A2 yang sama dapat dipindahkan antarkorpus tanpa adaptasi; dua arah diuji, PhiUSIIL→PhreshPhish dan PhreshPhish→PhiUSIIL. Tabel 7 memperlihatkan hasil seed 42. Referensi dalam-domain PhiUSIIL tetap mendekati plafon untuk kedua model, tetapi perilaku berubah tajam pada target.

Tabel 7. Transfer A2 seed 42 dengan model dan ambang 0,5 yang dibekukan, dua arah. Baris target tidak menggunakan fitting, kalibrasi, atau penyetelan ambang pada korpus target. Baris PhiUSIIL→PhreshPhish dievaluasi pada 168.035 baris uji temporal setelah penyaringan kanonik yang mengeluarkan 3 URL terlihat di latih dan 22 duplikat URL. Baris PhreshPhish→PhiUSIIL dievaluasi pada 235.370 baris PhiUSIIL, dan baris PhreshPhish dalam-sumber pada 168.060 baris blok uji sebelum rangkaian penyaringan kanonik yang sama diterapkan (eksperimen 9). Arah balik hanya memakai LightGBM, dan deduplikasi pada eksperimen 9 memakai string URL persis di dalam blok tanggal, bukan kunci URL kanonik yang dipakai eksperimen temporal dan ambang.

Model	Evaluasi	F1 phish	Precision	Recall	FPR benign	ROC-AUC	AP	MCC
LightGBM	PhiUSIIL dalam-domain	0,995985	0,998600	0,993384	0,001038	0,998101	0,998554	0,993017
LightGBM	PhiUSIIL→PhreshPhish zero-shot	0,599064	0,442058	0,929027	0,986478	0,382566	0,400534	−0,146445
LightGBM	PhreshPhish→PhiUSIIL zero-shot	0,549564	0,409503	0,835237	0,897783	0,642939	0,682202	−0,092320
LightGBM	PhreshPhish dalam-sumber	0,805958	0,889221	0,736953	0,077263	0,909696	0,913361	0,677473
XGBoost	PhiUSIIL dalam-domain	0,995659	0,998749	0,992589	0,000927	0,998172	0,998591	0,992455
XGBoost	PhiUSIIL→PhreshPhish zero-shot	0,601062	0,444544	0,927686	0,975181	0,324871	0,354125	−0,112337

Pada LightGBM, 90.025 dari 91.259 URL benign target diberi label phishing, sedangkan 71.327 dari 76.776 URL phishing terdeteksi. Recall 0,929 karena itu dicapai dengan FPR 0,986. ROC-AUC di bawah 0,5 dan MCC negatif menunjukkan bahwa masalahnya bukan sekadar ambang 0,5; urutan skor target juga berlawanan atau tidak informatif bagi banyak baris. Bootstrap domain seed 42 menghasilkan IK 95% F1 [0,538701; 0,669829], FPR [0,984874; 0,988138], ROC-AUC [0,353178; 0,413481], dan MCC [−0,175573; −0,111340]. Kelima seed menghasilkan metrik yang identik pada presisi pelaporan, sehingga pengulangan seed tidak memperluas dukungan temporal atau korpus.

Temuan ini lebih kuat daripada selisih statis pada Bagian 3.6 karena kontrak 18 fitur dan urutannya sama serta pipeline target benar-benar dibekukan; dua salinan ekstraktor dipakai pada eksperimen berbeda dan kesetaraan nilai keduanya tidak diverifikasi dalam artikel ini. Namun eksperimen tetap tidak menjelaskan *mengapa* transfer gagal. Perbedaan vendor, periode, prevalensi, dan distribusi URL hadir bersamaan; klaim yang sah terbatas pada kegagalan portabilitas PhiUSIIL→PhreshPhish pada konfigurasi yang diuji.

Uji arah sebaliknya dijalankan pada eksperimen 9 dengan prinsip yang sama: representasi A2, model yang dibekukan, dan ambang 0,5 tanpa penyesuaian pada target. Model dilatih hanya pada blok fit PhreshPhish (372.380 baris, 2 Juli 2024 sampai 30 Juni 2025), lalu diterapkan pada 235.370 baris PhiUSIIL hasil pembersihan. Kinerjanya juga buruk: F1 0,549564, FPR benign 0,897783, MCC −0,092320, dan ROC-AUC 0,642939. ROC-AUC di atas 0,5 menunjukkan pola pengurutan skor yang berbeda dari arah maju, sedangkan FPR 0,897783 menunjukkan ketidaksesuaian titik operasi pada kohort target: pada ambang beku 0,5, 89,8 % URL benign PhiUSIIL ditandai phishing. Sebagai pembanding titik, pengklasifikasi yang selalu memprediksi phishing pada korpus ini memperoleh F1 0,598529, sehingga F1 transfer terbalik pada ambang 0,5 berada di bawah baseline tersebut; perbandingan ini tidak berlaku untuk semua metrik atau semua ambang. Hasil ini tidak memisahkan kontribusi perubahan diskriminasi dari ketidaksesuaian kalibrasi, dan tidak menetapkan penyebab kegagalan transfer maupun menjamin bahwa kalibrasi ulang akan memulihkannya. Tumpang tindih URL persis antara blok latih dan target hanya 137 baris (0,058 %), sedangkan tumpang tindih registrable domain mencapai 21,6 % baris target; angka terakhir membatasi interpretasi dan tidak menyelamatkan kinerja. Interval bootstrap domain untuk arah balik tersedia pada artefak eksperimen 9 (F1 [0,512634; 0,586764], FPR [0,895279; 0,900180], MCC [−0,137850; −0,042795]; 1.000 replikasi, RNG seed 42, 175.509 domain). Eksperimen ini bukan evaluasi temporal karena PhiUSIIL tidak memiliki penanda waktu. Blok latih eksperimen ini berisi 372.380 baris, berbeda 167 baris dari 372.213 pada eksperimen ambang; rekonsiliasi menunjukkan selisih itu persis sama dengan jumlah duplikat URL kanonik di dalam jendela fit, karena eksperimen 9 melakukan deduplikasi pada string URL persis sedangkan jalur kanonik memakai kunci URL kanonik.

3.8 Trade-off Ambang Operasional

Tabel 8 menunjukkan hasil seed 13. Ambang dengan batas FPR dipilih hanya pada validasi, lalu diterapkan pada uji yang tidak berubah. Batas validasi tidak dipaksakan kembali pada uji; karena itu FPR uji dapat sedikit melampaui target. Model pada Tabel 8 dilatih ulang hanya pada blok fit, sehingga baris ambang bawaan 0,5 di sini tidak identik dengan Tabel 6; yang dibandingkan di dalam tabel ini adalah aturan ambang pada model yang sama.

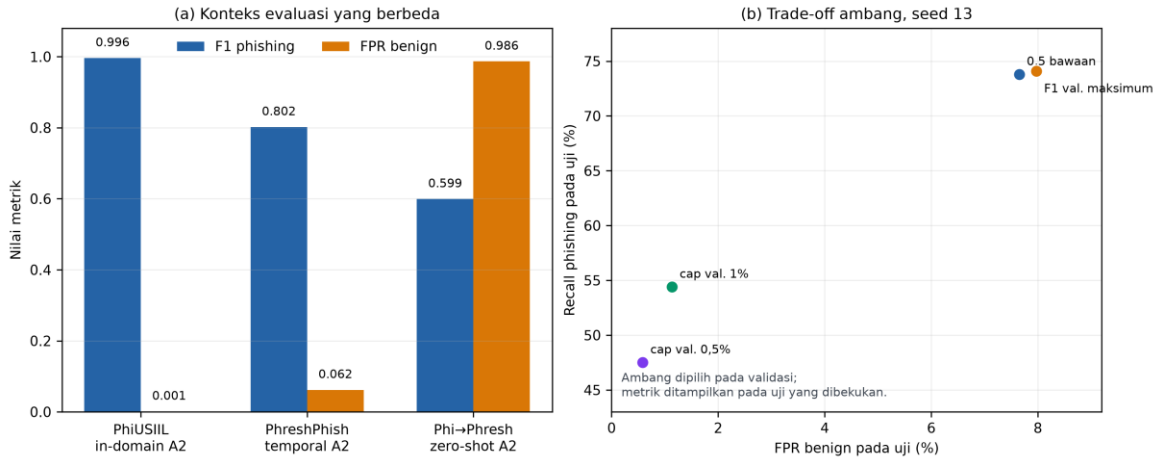
Tabel 8. Ambang berbasis validasi dan hasil uji temporal PhreshPhish, LightGBM/A2 seed 13. Model dilatih ulang hanya pada blok fit (372.213 baris); ambang dipilih pada blok validasi (125.146 baris) dan diterapkan sekali pada 168.035 baris uji.

Aturan	Ambang	F1 phish	Precision	Recall	FPR benign	FN	FP	MCC
Bawaan 0,5	0,500000	0,806999	0,890301	0,737952	0,076497	20.119	6.981	0,679280
FPR validasi ≤1%	0,884705	0,698557	0,975796	0,543998	0,011352	35.010	1.036	0,608973
FPR validasi ≤0,5%	0,937870	0,641062	0,985569	0,475018	0,005851	40.306	534	0,563984
F1 validasi maksimum	0,489218	0,807150	0,886566	0,740791	0,079740	19.901	7.277	0,677811

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 11
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Menurunkan FPR uji dari 7,65% menjadi 1,14% mengurangi alarm palsu dari 765 menjadi 114 per 10.000 URL benign, tetapi recall turun dari 0,738 menjadi 0,544 (Gambar 2b). Target validasi 0,5% menghasilkan FPR uji 0,585% dan recall 0,475. Pola lima seed konsisten: aturan 1% menghasilkan rerata F1 0,700739, recall 0,546658, dan FPR 0,011365; aturan 0,5% menghasilkan rerata F1 0,646167, recall 0,480645, dan FPR 0,005843. Ambang tidak memperbaiki diskriminasi model; ambang hanya memindahkan biaya antara FP dan FN. Pola ini konsisten dengan peringatan base-rate bahwa FPR kecil tidak menjamin proporsi alarm palsu yang kecil [21], dan dengan posisi bahwa precision-recall lebih informatif daripada ROC pada data tidak seimbang [22]; literatur khusus pemilihan ambang berbasis biaya tidak disintesis di sini.



Gambar 2. (a) F1 phishing dan FPR benign pada tiga konteks evaluasi seed utama; perbedaan bersifat deskriptif dan tidak mengidentifikasi mekanisme kausal saturasi karena protokol dan korpus tidak identik. (b) Trade-off recall–FPR pada kohort uji untuk empat ambang LightGBM seed 13 yang ditetapkan pada validasi. Titik dengan FPR lebih rendah mengorbankan recall secara substansial.

3.9 Taksonomi Galat

Taksonomi merekonstruksi confusion matrix seed 13 secara tepat: TN=85.629, FP=5.630, FN=21.636, dan TP=55.140. Tabel 9 menampilkan kategori yang paling relevan bagi interpretasi operasional; laju FP memakai penyebut benign di dalam kategori dan laju FN memakai penyebut phishing di dalam kategori.

Tabel 9. Kategori galat terpilih pada prediksi temporal LightGBM seed 13.

Kategori	n	Benign	Phishing	FP (laju)	FN (laju)	Batas pembacaan
Host platform	11.847	114	11.733	45 (39,47%)	8.035 (68,48%)	37,1% dari seluruh FN dalam kohort yang diperiksa; kategori tumpang tindih; ketidakpastian klaster tidak terverifikasi
Panjang URL ≤30	25.828	8.082	17.746	1.761 (21,79%)	1.939 (10,93%)	Campuran kelas dan domain berbeda
Non-HTTPS	13.570	2.083	11.487	751 (36,05%)	556 (4,84%)	Skema berkorelasi dengan sumber URL
Domain belum terlihat	71.804	28.896	42.908	2.592 (8,97%)	9.555 (22,27%)	Prevalensi berbeda dari domain terlihat
Domain terlihat	96.231	62.363	33.868	3.038 (4,87%)	12.081 (35,67%)	Tidak mengisolasi memorisasi domain

Sebanyak 8.035 FN berada pada kategori host platform, terutama `pages.dev` (7.341 FN); jumlah tersebut adalah 37,1% dari seluruh FN dalam kohort yang diperiksa. Kuantifikasi ketidakpastian antar-klaster domain untuk proporsi ini tidak memiliki komputasi yang dapat direproduksi dan tidak digunakan sebagai interval inferensial. URL dengan query juga menggambarkan risiko penyebut kecil: seluruh 52 URL benign berquery menjadi FP, sementara kategori tersebut mencakup 18.396 URL phishing dan hanya 13 FN. Karena itu, laju 100% pada subset benign berukuran 52 tidak boleh dijadikan aturan deteksi. Taksonomi ini mengidentifikasi lokasi galat deskriptif untuk hipotesis lanjutan, bukan bukti bahwa kategori menyebabkan galat.

Tabel 10 merangkum angka deskriptif yang dibahas di luar tabel utama beserta artefak sumbernya, sehingga setiap angka yang dikutip di dalam teks dapat ditelusuri.

Tabel 10. Angka deskriptif yang dilaporkan di luar Tabel 3 sampai Tabel 9 beserta artefak sumbernya.

Angka	Nilai	Artefak sumber
Selisih F1 acak terhadap site-disjoint, minimum (A0/XGBoost)	0,000162	summary.csv (eksperimen 5): 0,999855755 − 0,999693299

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 12
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Selisih F1 acak terhadap site-disjoint, maksimum (A2/LightGBM)	0,001178	summary.csv (eksperimen 5): 0,996364752 − 0,995186381
Kesalahan A0→A1 LightGBM, rerata 5 seed pada 44.213,6 baris uji	12,8 → 32,2	metrics_all.csv (Eksperimen 5)
Kesalahan A0→A1 XGBoost, rerata 5 seed pada 44.213,6 baris uji	10,4 → 39,0	metrics_all.csv (Eksperimen 5)
IK 95 % F1 transfer LightGBM	[0,538701; 0,669829]	primary_seed_domain_bootstrap.csv
IK 95 % FPR benign transfer LightGBM	[0,984874; 0,988138]	primary_seed_domain_bootstrap.csv
IK 95 % ROC-AUC transfer LightGBM	[0,353178; 0,413481]	primary_seed_domain_bootstrap.csv
IK 95 % MCC transfer LightGBM	[−0,175573; −0,111340]	primary_seed_domain_bootstrap.csv
Waktu latih LightGBM temporal (5 seed)	6,06–7,21 detik	results_per_seed.csv (run 20261022T170935017991Z, run kanonik)
Waktu prediksi batch 168.035 baris	0,79–0,84 detik	results_per_seed.csv (run 20261022T170935017991Z, run kanonik)
Rerata lima seed, aturan FPR validasi <= 1 % (F1; recall; FPR)	0,700739; 0,546658; 0,011365	test_metrics_across_seeds.csv
Rerata lima seed, aturan FPR validasi <= 0,5 % (F1; recall; FPR)	0,646167; 0,480645; 0,005843	test_metrics_across_seeds.csv
FN kategori host platform, termasuk pages.dev	8.035 (pages.dev 7.341)	category_error_table.csv (8.035); platform_fn_breakdown.csv dan README.md eksperimen 8 (rincian pages.dev 7.341, dilaporkan sebagai angka prosa)
FP dan FN kategori query_present	52 FP; 13 FN	category_error_table.csv
AUC tunggal tiga kolom sumber: URLSimilarityIndex (dibuang); LineOfCode dan NoOfExternalRef (dipertahankan dalam A0)	0,9961; 0,9903; 0,9880	phiusiil_leakage_audit.md
Rerata lima seed F1 temporal A2/LightGBM (seluruh 168.035 baris uji)	0,800461	summary.csv (eksperimen 5), protokol temporal; simpangan baku 0,001184
Rerata lima seed F1 temporal A2/XGBoost (seluruh 168.035 baris uji)	0,799629	summary.csv (eksperimen 5), protokol temporal; simpangan baku 0 (prosedur histogram deterministik)
Aturan FPR validasi <= 1 %: FPR uji, recall uji, ambang terpilih	1,1352 %; 0,5440; 0,884705	test_metrics_primary_seed.csv (eksperimen 7, seed 13)
Aturan ambang 0,5: FPR uji dan recall uji	7,6497 %; 0,7380	test_metrics_primary_seed.csv (eksperimen 7, seed 13)
FPR pada URL benign dengan panjang <= 30 karakter	21,8 %	category_error_table.csv (eksperimen 8), kategori url_length_band <=30
Registrable domain unik dan baris ber-alamat IP pada PhiUSIIL	175.509; 636	phiusiil_leakage_audit.md

3.10 Pembahasan

Temuan audit konsisten dengan literatur yang menempatkan desain dataset, ketidakmandirian sampel, dan stabilitas fitur sebagai ancaman terhadap generalisasi [2], [3], [5], [6], [9]. Pada PhiUSIIL, selisih rerata teramati antarprotokol kecil, yaitu 0,0002–0,0012 dalam F1; nilai ini tidak dibandingkan secara numerik dengan studi yang menggunakan korpus atau protokol berbeda. Dua kolom A0 memiliki AUC tunggal sekitar 0,988 atau lebih, sementara metrik A0 teramati mendekati satu. Pola ini konsisten dengan saturasi benchmark deskriptif, tetapi penelitian tidak menetapkan mekanismenya atau memisahkan kontribusi relatif fitur dan paparan domain. Nilai AUC menunjukkan separabilitas kelas saja; nilai tersebut tidak menunjukkan bahwa fitur tersimpan independen dari label atau paparan domain.

Implikasinya bersifat metodologis, bukan kompetitif. Perbedaan kecil F1 *site-disjoint*–acak yang teramati perlu dilaporkan bersama F1 absolut yang mendekati satu serta AUC tunggal dua kolom yang dipertahankan dalam A0. Hasil tersebut menggambarkan benchmark ini; hasil itu tidak menetapkan penyebabnya atau efek kausal protokol. Kedua angka perlu dilaporkan bersama tanpa menyebut kedua kolom sebagai proksi label yang telah terbukti.

Kontras A1−A0 pada Subbagian 3.4 menunjukkan perbedaan terukur dengan besar efek sekitar seperseribu F1; hasil itu tidak mengidentifikasi mekanisme saturasi maupun konsekuensi deployment. Konsekuensi deployment tidak dapat disimpulkan tanpa prevalensi, biaya kesalahan, dan pemilihan ambang yang relevan.

Rangkaian eksperimen mengubah posisi kontribusi artikel ini. Nilai model tidak melampaui *state of the art*; justru eksperimen menunjukkan bahwa skor hampir sempurna pada PhiUSIIL tidak menjamin portabilitas. Evaluasi temporal dalam-korpus menghasilkan F1 sekitar 0,80, sedangkan transfer PhiUSIIL→PhreshPhish dengan A2 yang sama turun menjadi sekitar 0,60 dan salah menandai hampir seluruh URL benign. Hasil ambang kemudian memperlihatkan bahwa FPR dapat ditekan, tetapi biayanya adalah penurunan recall sekitar 19–26 poin persentase. Keunggulan penelitian ini karena itu berada pada desain evaluasi dan batas klaim, bukan pada nilai klasifikasi tertinggi.

Keterbatasan penelitian membatasi generalisasi secara tegas. Pertama, hanya dua korpus, dua keluarga gradient boosting, dua arah transfer (PhiUSIIL→PhreshPhish dan PhreshPhish→PhiUSIIL), dan satu snapshot target yang diuji; hasil tidak mewakili seluruh feed phishing atau periode lain. Kedua, transfer langsung mengontrol representasi dan adaptasi target, tetapi tidak memisahkan penyebab pergeseran karena vendor, waktu, populasi, dan prevalensi berubah bersama. Ketiga, fold sumber transfer berasal dari pembagian acak PhiUSIIL; F1 sumber karena itu bukan estimasi portabilitas ke domain baru. Keempat, ambang dipilih pada satu periode validasi PhreshPhish dan hanya diuji pada satu periode berikutnya; pencapaian batas FPR validasi tidak menjamin batas yang sama pada deployment. Kelima, taksonomi memakai kategori yang ditentukan

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

manual, kedalaman subdomain perkiraan tanpa snapshot PSL privat, dan interval Wilson per baris yang tidak menangkap klaster domain; analisis tersebut eksploratif karena kohort uji telah diperiksa. Keenam, variasi seed tidak menggantikan variasi korpus atau periode, dan XGBoost deterministik pada konfigurasi tertentu. Ketujuh, penelitian tidak membandingkan ulang seluruh metode SOTA dalam pipeline yang sama, sehingga tidak mendukung klaim peringkat performa.

4. KESIMPULAN

Penelitian ini menunjukkan mengapa kinerja benchmark, evaluasi temporal dalam-korpus, dan portabilitas lintas-korpus perlu dibedakan pada deteksi phishing URL. Pada PhiUSIIL, F1 *site-disjoint* adalah 0,999623 bersama dua fitur yang dipertahankan dengan AUC tunggal sekitar 0,988 atau lebih. Kontras kelompok A1−A0 sekitar seperseribu F1. Temuan ini menggambarkan saturasi pada benchmark tersebut; penelitian tidak menetapkan penyebabnya.

Evaluasi temporal A2 dalam PhreshPhish mencapai rerata F1 0,800461. Uji yang lebih ketat—melatih A2 hanya pada PhiUSIIL dan menerapkannya tanpa adaptasi pada PhreshPhish—menghasilkan F1 0,599064, FPR 0,986478, ROC-AUC 0,382566, dan MCC negatif untuk LightGBM seed 42. Hasil tersebut menunjukkan kegagalan portabilitas pada pasangan korpus yang diuji, tetapi tidak mengidentifikasi penyebab distribusionalnya.

Pemilihan ambang berbasis validasi dapat menekan FPR uji dari 7,65% menjadi 1,14%, tetapi recall turun dari 0,738 menjadi 0,544. Analisis galat deskriptif menemukan 37,1% dari seluruh FN pada kategori host platform dan FPR 21,8% pada URL benign dengan panjang paling banyak 30 karakter. Ketidakpastian antar-klaster domain untuk proporsi FN platform belum terkuantifikasi secara reproduktif dan tidak digunakan untuk inferensi. Kategori kohort ini saling tumpang tindih dan tidak menetapkan kelayakan operasional, yang tidak dapat disimpulkan dari F1 saja.

Kontribusi artikel ini bukan model baru atau skor SOTA, melainkan rantai audit yang dapat ditelusuri melalui artefak tersimpan dan membatasi klaim pada bukti yang benar-benar diuji. Validasi berikutnya dapat menggunakan snapshot waktu tambahan atau feed eksternal yang belum pernah diperiksa; klaim prospektif memerlukan kohort baru dan protokol terdokumentasi yang membatasi akses terhadap label serta hasilnya. Pengujian kategori galat dengan model multivariat atau rancangan terkontrol memerlukan bukti tersendiri. Dataset tambahan tersebut sebaiknya diperlakukan sebagai validasi eksternal terencana, bukan ditambahkan tanpa pertanyaan penelitian yang spesifik.

5. PERNYATAAN PENULIS

5.1 Kontribusi Penulis

Bagian ini menegaskan kontribusi nyata masing-masing penulis mengikuti taksonomi CRediT:

Konseptualisasi: penulis1;

Metodologi: penulis1, penulis2;

Perangkat Lunak: penulis1;

Validasi: penulis1, penulis2;

Analisis Formal: penulis1;

Investigasi: penulis1;

Sumber Daya: penulis1;

Kurasi Data: penulis1;

Penulisan – draf awal: penulis1;

Penulisan – tinjauan dan penyuntingan: penulis1, penulis2, penulis3;

Visualisasi: penulis1;

Supervisi: penulis2, penulis3;

Administrasi Proyek: penulis1;

Perolehan Pendanaan: tidak ada dana eksternal; penelitian didanai mandiri oleh para penulis.

Seluruh penulis telah membaca dan menyetujui versi akhir manuskrip ini.

5.2 Ketersediaan Data

Paket tinjauan kandidat disusun dalam lima direktori utama: 01_MANUSCRIPT (naskah kandidat dan hasil render), 02_CLAIM_EVIDENCE (audit Stage-1, QA P0, register perubahan P1, serta ledger sumber), 03_EXPERIMENTS (notebook yang telah dieksekusi beserta metrik, ledger, dan artefak run temporal kanonik), 04_ENVIRONMENT (catatan dependensi dan perintah yang diuji), dan 05_LIMITATIONS (bukti yang belum tersedia serta batas reproduksi). Setiap berkas didaftarkan pada MANIFEST.csv bersama peran, ukuran, SHA-256, dan status reproduksi; MANIFEST.sha256 memuat checksum untuk pemeriksaan mandiri. Paket ini tidak memuat korpus mentah PhiUSIIL dan PhreshPhish, biner model terlatih, pemisahan baris lengkap, prediksi per baris, arsip duplikat, dan cache yang dihasilkan alat bantu. Artefak yang dikecualikan beserta alasannya didaftarkan terpisah pada OMITTED_ARTIFACTS.csv, dengan status INCLUDED, WORKSPACE_ONLY, MISSING, OMITTED_SIZE, OMITTED_LICENSE_PRIVACY, atau NOT_REQUIRED. Karena itu paket ini adalah bundel bukti yang dapat diaudit, bukan bundel yang dapat direproduksi penuh di lingkungan bersih tanpa mengambil data dari penyedia aslinya. Salinan paket tersedia pada repositori publik https://github.com/Handy-Wibowo/supreme-sniffle dan diarsipkan dengan DOI konsep 10.5281/zenodo.23847784, dengan MANIFEST.sha256 untuk verifikasi independen; DOI konsep tersebut selalu menunjuk rilis terbaru. Artefak yang dikecualikan tidak dihasilkan oleh

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

satu skrip tunggal, dan pemetaan berikut menyebut artefak yang benar-benar tersedia. Pembersihan dan pembagian PhiUSIIL disiapkan oleh notebook tahap awal, dengan split_random.csv dan split_sitedisjoint.csv sebagai manifest ID-fold yang menjadi masukan setiap arm. Benchmark A0/A1/A2 dan ablasi dibangkitkan oleh paired_bootstrap_E4/src/run_experiment.py dan diringkas oleh paired_bootstrap_E4/src/summarize.py; nama folder historis E4 tidak berarti notebook E3 menghasilkan benchmark final, dan notebook 03_evaluation_pipeline_v2_run_complete.ipynb memakai keluarga fitur serta konvensi label yang berbeda sehingga tidak dipakai untuk metrik positif-phishing. Evaluasi temporal memakai temporal_scripts/run_temporal.py untuk jalur kanonik, sedangkan interval yang dikutip Tabel 6 berasal dari paired_bootstrap_E4/bootstrap_temporal.csv. Transfer maju dijalankan oleh Exp6_Cross_Corpus/transfer.executed.ipynb; evaluasi ambang oleh Exp7_Operational_Threshold/01_operational_thresholds.executed.ipynb dengan paket src eksperimen 7; taksonomi galat oleh Exp8_Error_Taxonomy/error_taxonomy.executed.ipynb; dan transfer balik oleh Exp9_reverse_transfer/reverse_transfer.ipynb. Kedua manifest split memuat 1.176.850 baris, yaitu lima seed kali 235.370 URL; yang tidak dibundel adalah data mentah, biner model, dan prediksi per baris, bukan manifest ID-fold. Snapshot arsip yang dirujuk adalah DOI versi 10.5281/zenodo.23860185 di bawah DOI konsep 10.5281/zenodo.23847784.

5.3 Pendanaan

Penelitian ini didanai mandiri oleh para penulis (self-funded).

5.4 Pernyataan Dewan Peninjau Institusional

Tidak Berlaku (Not applicable).

5.5 Pernyataan Persetujuan Berdasarkan Informasi

Tidak Berlaku (Not applicable).

5.6 Pernyataan Konflik Kepentingan

Para penulis menyatakan bahwa mereka tidak memiliki kepentingan keuangan yang bersaing atau hubungan pribadi yang diketahui yang dapat dianggap memengaruhi pekerjaan yang dilaporkan dalam artikel ini.

5.7 Penggunaan AI Generatif dan Teknologi Berbantuan AI dalam Proses Penulisan

Para penulis menggunakan AI Generatif untuk membantu penyusunan draf dan penyuntingan bahasa pada artikel ini. Seluruh konten telah ditinjau, diverifikasi, dan disunting oleh para penulis yang bertanggung jawab penuh atas integritas dan akurasi karya.

REFERENCES

[1] A. Prasad and S. Chandra, "PhiUSIIL: A diverse security profile empowered phishing URL detection framework based on similarity index and incremental learning," *Computers & Security*, vol. 136, Art. no. 103545, 2024, doi: 10.1016/j.cose.2023.103545.

[2] T. Dalton, H. Gowda, G. Rao, S. Pargi, A. H. Khodabakhshi, J. Rombs, S. Jou, and M. Marwah, "PhreshPhish: A real-world, high-quality, large-scale phishing website dataset and benchmark," arXiv:2507.10854, 2025. [Preprint].

[3] S. Marchal and N. Asokan, "On designing and evaluating phishing webpage detection techniques for the real world," in *Proc. 11th USENIX Workshop on Cyber Security Experimentation and Test (CSET 18)*, Baltimore, MD, USA, 2018.

[4] A. El Aassal, S. Baki, A. Das, and R. M. Verma, "An in-depth benchmarking and evaluation of phishing detection research for security needs," *IEEE Access*, vol. 8, pp. 22170–22192, 2020, doi: 10.1109/ACCESS.2020.2969780.

[5] D. Arp, E. Quiring, F. Pendlebury, A. Warnecke, F. Pierazzi, C. Wressnegger, L. Cavallaro, and K. Rieck, "Dos and don'ts of machine learning in computer security," in *Proc. 31st USENIX Security Symposium*, Boston, MA, USA, 2022, pp. 3971–3988.

[6] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, Art. no. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[7] A. Das, S. Baki, A. El Aassal, R. Verma, and A. Dunbar, "SoK: A comprehensive reexamination of phishing research from the security perspective," *IEEE Communications Surveys & Tutorials*, vol. 22, no. 1, pp. 671–708, 2020, doi: 10.1109/COMST.2019.2957750.

[8] A. Hannousse and S. Yahiouche, "Towards benchmark datasets for machine learning based website phishing detection: An experimental study," *Engineering Applications of Artificial Intelligence*, vol. 104, Art. no. 104347, 2021, doi: 10.1016/j.engappai.2021.104347.

[9] M. Mia, D. Derakhshan, and M. M. A. Pritom, "Can features for phishing URL detection be trusted across diverse datasets? A case study with explainable AI," in *Proc. 11th Int. Conf. Networking, Systems, and Security (NSysS)*, 2024, pp. 137–145, doi: 10.1145/3704522.3704532.

[10] A. Odeh, Q. Abu Al-Haija, A. Aref, and A. Abu Taleb, "Comparative study of CatBoost, XGBoost, and LightGBM for enhanced URL phishing detection: A performance assessment," *Journal of Internet Services and Information Security*, vol. 13, no. 4, pp. 1–11, 2023, doi: 10.58346/JISIS.2023.I4.001.

[11] N. Nabila, E. Hesti, and A. Aryanti, "Deteksi URL phishing menggunakan natural language processing dan support vector machine berbasis machine learning," *Building of Informatics, Technology and Science (BITS)*, vol. 7, no. 1, pp. 526–537, 2025, doi: 10.47065/bits.v7i1.7443.

[12] Y. Yoga, F. R. Umbara, and P. N. Sabrina, "Klasifikasi website phishing menggunakan metode XGBoost dengan teknik penyeimbang data radial based undersampling," *Building of Informatics, Technology and Science (BITS)*, vol. 7, no. 2, pp. 1153–1163, 2025, doi: 10.47065/bits.v7i2.7920.

[13] F. Pendlebury, F. Pierazzi, R. Jordaney, J. Kinder, and L. Cavallaro, "TESSERACT: Eliminating experimental bias in malware classification across space and time," in *Proc. 28th USENIX Security Symposium (USENIX Security 19)*, Santa Clara, CA, USA, 2019, pp. 729–746.

[14] R. Jordaney, K. Sharad, S. K. Dash, Z. Wang, D. Papini, I. Nouretdinov, and L. Cavallaro, "Transcend: Detecting concept drift in malware classification models," in *Proc. 26th USENIX Security Symposium (USENIX Security 17)*, Vancouver, BC, Canada, 2017, pp. 625–642.

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*.
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

[15] F. Barbero, F. Pendlebury, F. Pierazzi, and L. Cavallaro, "Transcending TRANSCEND: Revisiting malware classification in the presence of concept drift," in *Proc. IEEE Symposium on Security and Privacy (SP)*, San Francisco, CA, USA, 2022, pp. 805–823, doi: 10.1109/SP46214.2022.9833659.

[16] A. Safi and S. Singh, "A systematic literature review on phishing website detection techniques," *Journal of King Saud University - Computer and Information Sciences*, vol. 35, no. 2, pp. 590–611, 2023, doi: 10.1016/j.jksuci.2023.01.004.

[17] A. Karim, M. Shahroz, K. Mustofa, S. B. Belhouari, and S. R. K. Joga, "Phishing detection system through hybrid machine learning based on URL," *IEEE Access*, vol. 11, pp. 36805–36822, 2023, doi: 10.1109/ACCESS.2023.3252366.

[18] A. Chaudhuri and B. Mohankumar, "Adversarial-resilient lightweight phishing URL detection: Evaluating lexical and metadata features under evasion techniques," *Scientific Reports*, vol. 16, 2026, doi: 10.1038/s41598-026-60046-3.

[19] M. Sánchez-Paniagua, E. Fidalgo, E. Alegre, W. Al-Nabki, and V. González-Castro, "Phishing URL detection: A real-case scenario through login URLs," *IEEE Access*, vol. 10, pp. 42949–42960, 2022, doi: 10.1109/ACCESS.2022.3168681.

[20] S. Aslam, H. Aslam, A. Manzoor, C. Hui, and A. Rasool, "AntiPhishStack: LSTM-based stacked generalization model for optimized phishing URL detection," *Symmetry*, vol. 16, no. 2, Art. no. 248, 2024, doi: 10.3390/sym16020248.

[21] S. Axelsson, "The base-rate fallacy and the difficulty of intrusion detection," *ACM Transactions on Information and System Security*, vol. 3, no. 3, pp. 186–205, 2000, doi: 10.1145/357830.357849.

[22] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, no. 3, Art. no. e0118432, 2015, doi: 10.1371/journal.pone.0118432.

[23] F. S. Trad and A. Chehab, "Prompt engineering or fine-tuning? A case study on phishing detection with large language models," *Machine Learning and Knowledge Extraction*, vol. 6, no. 1, pp. 367–384, 2024, doi: 10.3390/make6010018.

[24] T. Ahamed, S. C. Kakon, F. Al Farid, J. Uddin, and H. B. A. Karim, "An integrated evaluation protocol for adversarial robustness, generalization, and explanation stability in URL-based phishing detection," *Frontiers in Computer Science*, vol. 8, 2026, doi: 10.3389/fcomp.2026.1834407.

Lampiran A. Ringkasan Protokol untuk Replikasi

Lampiran ini merangkum protokol yang diperlukan untuk merekonstruksi eksperimen. Setiap butir diambil dari artefak yang tersimpan, bukan dari rekonstruksi naratif. Butir yang tidak tercatat pada artefak dinyatakan sebagai tidak tercatat, bukan diisi dengan perkiraan.

Tabel A1. Ringkasan protokol eksperimen dan provenance artefak.

[25] S. M. N. Ahmed, A. H. Khan, and M. M. Rashid, "Explainable gradient boosting for transparent phishing URL detection: A cross-dataset, statistically validated SHAP analysis of XGBoost, LightGBM, and CatBoost," *Journal of Cyber Security*, vol. 8, pp. 668–703, 2026, doi: 10.32604/jcs.2026.089357.

[26] M. Alam, M. L. Rahman, S. K. Paul, A. W. Hays, A. Hussain, M. I. Huq, and N. Saxena, "SoK: PHILTER: Uncovering security and functional gaps in AI-based phishing website detection literature via an LLM-based reasoning framework," in *Proc. USENIX Security Symposium (USENIX Security 26)*, 2026. [Preprint].

[27] F. Rashid, B. Doyle, S. C. Han, and S. Seneviratne, "Phishing URL detection generalisation using Unsupervised Domain Adaptation," *Computer Networks*, vol. 245, Art. no. 110398, 2024, doi: 10.1016/j.comnet.2024.110398.

[28] A. Kulkarni, V. Balachandran, and T. Das, "Phishing webpage detection: Unveiling the threat landscape and investigating detection techniques," *IEEE Communications Surveys & Tutorials*, vol. 26, 2024, doi: 10.1109/COMST.2024.3441752.

[29] F. Ceschin, M. Botacin, A. Bifet, B. Pfahringer, L. S. Oliveira, H. M. Gomes, and A. Grégio, "Machine learning (in) security: A stream of problems," *Digital Threats: Research and Practice*, vol. 4, no. 1, 2023, doi: 10.1145/3617897.

[30] J.-G. Gaudreault and P. Branco, "Empirical analysis of performance assessment for imbalanced classification," *Machine Learning*, vol. 113, pp. 5533–5575, 2024, doi: 10.1007/s10994-023-06497-5.

[31] A. Kulkarni, V. Balachandran, D. M. Divakaran, and T. Das, "From ML to LLM: Evaluating the robustness of phishing web page detection models against adversarial attacks," *Digital Threats: Research and Practice*, 2025, doi: 10.1145/3737295.

[32] S. Henry, B. U.-A. Stephen, and P. Asuquo, "Ensemble transfer learning for cross-dataset phishing detection," *Franklin Open*, vol. 15, Art. no. 100579, 2026, doi: 10.1016/j.fraope.2026.100579.

Komponen	Ringkasan terverifikasi
Snapshot PhiUSIIL	235.370 baris setelah pembersihan. Split memakai berkas beku split_random.csv dan split_sitedisjoint.csv (kolom seed, url_id, fold) untuk lima seed; lipatan val ada di berkas tetapi tidak dipakai pada protokol. Pada seed 13: acak 141.222 latih / 47.074 val / 47.074 uji; site-disjoint 143.800 / 48.280 / 43.290.
Snapshot PhreshPhish	77 shard parquet (train-000... dan test-000...), 666.315 baris, 36,58 GB; SHA-256 per berkas tercatat pada input_manifest.json. Keanggotaan split resmi train/test dipakai sebagai kerangka, bukan dibentuk ulang, tetapi blok temporal tetap melewati penyaringan: 681 baris latih pada atau setelah cutoff dikeluarkan sebelum blok fit dibentuk. Penanda tanggal diperlakukan sebagai tanggal pada berkas sumber.
Ledger eksklusi	921 baris dikeluarkan dengan alasan tercatat: 681 setelah cutoff, 214 duplikat URL latih, 22 duplikat URL uji, 3 URL uji terlihat di latih, dan 1 URL tak dapat diparse. Latih 498.255 menjadi 497.359; uji 168.060 menjadi 168.035.
Label	Untuk PhreshPhish, nilai sumber berupa string benign/phish dan dipetakan ke 0/1; pipeline temporal dan ambang menolak nilai di luar himpunan itu. PhiUSIIL memakai pengodean numerik sumber 1 = legitim dan 0 = phishing, lalu dipetakan menjadi phishing = 1 pada analisis. Eksperimen 9 hanya membandingkan label PhreshPhish dengan string phish dan mencetak domain label, tanpa penolakan eksplisit; keluarannya hanya benign dan phish.
Konfigurasi fitur	A0 47 fitur, A1 41 fitur, A2 18 fitur. Daftar ketiganya didefinisikan pada src/data.py; A2 mengikuti urutan feature_schema.json dengan sumber deterministic URL-only dan tanpa target encoding.

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 16
This work is licensed under a Creative Commons Attribution 4.0 International License.

Building of Informatics, Technology and Science (BITS)
ISSN 2684-8910 (media cetak), ISSN 2685-3310 (media online)
Volume 99, No 99, Bulan 2023 Page: 999−999
DOI 10.47065/bits.v9i9.999
https://ejurnal.seminar-id.com/index.php/bits

Ekstraktor A2	Dua salinan dipakai pada eksperimen berbeda. Eksperimen 7 memakai src/features.py dengan SHA-256 c98b119c72c77df225bd21b7f803c367b71a934630622b3349ddecf349dc5864; eksperimen 5 dan 9 memakai salinan dengan SHA-256 81822b4fac8b50cdf93371651e3c94680628ef189d64c32429ec15cc51cd48e6. Keduanya dihitung deterministik per URL tanpa fitur halaman. Kesetaraan nilai fitur antar kedua salinan tidak diperiksa pada artikel ini; yang dinyatakan adalah kontrak 18 fitur dan urutan yang sama.
Model	LightGBM 300 estimator, learning rate 0,05, 63 daun. XGBoost 300 estimator, learning rate 0,05, max_depth 8, eval_metric logloss, tree_method hist. Tidak ada penyetelan hiperparameter pada korpus target.
Lingkungan	lightgbm 4.7.0, xgboost 3.4.1, scikit-learn 1.9.1, tldextract 5.4.0, pandas 3.1.0, NumPy 2.5.3; snapshot Public Suffix List ber-SHA-256 b69315c085d53972724b8f2df111ffc329b0c84fe0a47d62c8c91655cc774a38.
Bootstrap	Interval persentil; unit registrable domain diresample dengan pengembalian, 1.000 replikasi, seed RNG 42. Varian berpasangan menjaga pasangan model tetap dan menghitung selisih pada replikasi yang sama.
Pemilihan ambang	Aturan prediksi adalah skor >= ambang. Kandidat ambang adalah seluruh nilai probabilitas unik pada blok validasi, dan nilai kembar ditangani sebagai satu blok nilai.
Taksonomi	14 domain platform eksplisit (github.io, pages.dev, vercel.app, netlify.app, weebly.com, wixsite.com, blogspot.com, wordpress.com, tumblr.com, typedream.app, gitlab.io, firebaseapp.com, web.app, workers.dev) dan 10 domain shortener; kategori biner: host_is_ip, host_punycode, query_present, scheme_https, domain_seen, shortener, platform.
Waktu komputasi	Metadata run mencatat 16 CPU logis, konfigurasi n_jobs = -1, dan identifikasi CPU generik; jumlah thread efektif, RAM, dan kondisi beban sistem tidak dicatat. Angka waktu karena itu adalah log eksekusi, bukan pembandingan biaya komputasi.

Copyright © 2026 The Author(s). Published by *Forum Kerjasama Pendidikan Tinggi*. Page 17
This work is licensed under a Creative Commons Attribution 4.0 International License.